

# **Tugas Besar AK 2281 Analisis Deret Waktu - Analisis Kualitas Udara Berbasis Indeks Standar Pencemaran Udara (ISPU) di DKI Jakarta**

Tabina Wan Kedana<sup>1, a)</sup>, Antonius<sup>1, b)</sup>, Pamela Cathryn<sup>1, c)</sup>, Jeremy<sup>1, d)</sup>

<sup>1</sup>*Institut Teknologi Bandung, Jl. Ganesa No.10, Lb. Siliwangi, Kecamatan Coblong, Kota Bandung, Jawa Barat, Indonesia*

Email: <sup>a)</sup>10820002@mahasiswa.itb.ac.id, <sup>b)</sup>10820007@mahasiswa.itb.ac.id,  
<sup>c)</sup>10820033@mahasiswa.itb.ac.id, <sup>d)</sup>10820034@mahasiswa.itb.ac.id

## **Abstract**

*The issue of air pollution is closely related to the 7th Sustainable Development Goal (SDG), namely Clean and Affordable Energy, and the 13th SDG, namely Climate Change Management. According to a report from sciencedirect.com, air pollutant emissions will cause 40% more deaths than today, carbon emissions will increase by 0.4% annually, and almost 2 billion people will have difficulty getting clean air. This study aims to (1) Model the amount of PM10 particulates in DKI Jakarta using the SARIMA model, (2) Predict the amount of PM10 particulates in DKI Jakarta for two years after October 2021, and (3) Determine the air quality at several points in DKI Jakarta (Bundaran HI, Kelapa Gading, Jagakarsa, and Lubang Buaya). The research method used is literature study and SARIMA time series data modeling. The forecasting results show that DKI Jakarta has air quality that is classified as moderate.*

**Keywords:** Air Pollution, PM10, SARIMA.

## **Abstrak**

Masalah Pencemaran Udara berkaitan erat dengan *Sustainable Development Goal* (SDG) ke-7, yaitu Energi Bersih dan Terjangkau, dan SDG ke-13, yaitu Penanganan Perubahan Iklim. Dilansir dari sciencedirect.com, Emisi polutan udara akan menyebabkan 40% lebih banyak kematian dini daripada saat ini, emisi karbon akan meningkat sebesar 0,4% tiap tahunnya, dan hampir 2 miliar orang akan kesusahan mendapatkan udara bersih. Penelitian ini bertujuan untuk (1) Memodelkan jumlah partikulat PM10 di DKI Jakarta menggunakan model SARIMA, (2) Melakukan prediksi jumlah partikulat PM10 di DKI Jakarta selama dua tahun setelah Oktober 2021, dan (3) Mengetahui kategori kualitas udara di beberapa titik DKI Jakarta (Bundaran HI, Kelapa Gading, Jagakarsa, dan Lubang Buaya). Metode penelitian yang digunakan adalah studi literatur dan pemodelan data deret waktu SARIMA. Hasil prakiraan menunjukkan DKI Jakarta memiliki kualitas udara yang masuk dalam klasifikasi sedang.

**Kata-kata kunci:** Pencemaran Udara, PM10, SARIMA.

## **PENDAHULUAN**

Perubahan iklim adalah salah satu masalah yang belum dapat diselesaikan oleh manusia. Masalah tersebut diperparah dengan kenaikan emisi polutan udara akibat dari revolusi industri dan kemajuan teknologi. Penelitian ini dilakukan dengan alasan perubahan iklim akibat kemajuan teknologi dan faktor-faktor, seperti Jakarta merupakan salah satu kota paling berpolusi di dunia lalu dianalisis dari tingkat PM10 di Jakarta. *Sustainable Development Goals* (SDGs) yang terkait dari penelitian yang dilakukan adalah SDG ke-7, yaitu Energi Bersih dan Terjangkau, dan SDG ke-13, yaitu Penanganan Perubahan Iklim. data yang digunakan adalah data Indeks Standar Pencemaran Udara (ISPU) di DKI Jakarta yang

diambil dari Jakarta Open Data. Data tersebut dipilih karena data tersebut memiliki data PM10 yang lengkap dan ekstensif.

Salah satu kajian literatur laporan ini adalah penelitian yang dilakukan oleh D.A Suryanto pada tahun 2012 yang berjudul Analisis Tingkat Polusi Udara Terhadap Pengaruh Pertumbuhan Kendaraan Studi Kasus DKI Jakarta yang dikutip dari *e-journal Gunadarma*. penelitian ini meneliti tingkat polusi udara di Jakarta dari sisi polutan yang dihasilkan oleh kendaraan bermotor. Penelitian ini pun menghasilkan model yang bergantung pada CO (karbon monoksida), HC (hidrokarbon), dan NO (natrium monoksida). Hasil dari penelitian tersebut menyimpulkan bahwa terdapat relasi hasil tingkat polusi udara terhadap pengaruh pertumbuhan kendaraan. Berbeda dengan penelitian yang telah dilakukan oleh D.A Suryanto tersebut kami menganalisis kualitas udara dari sisi PM10. PM10 tidak mengukur partikel-partikel seperti CO, HC, dan NO, tetapi PM10 terdiri dari partikel-partikel yang memiliki diameter kurang dari 10 mikron dapat membahayakan bagi manusia dan mengakibatkan gejala batuk-batuk atau bahkan asma. Perbedaan ini dapat menghasilkan analisis yang berbeda dan melihat kualitas udara di Jakarta dari sudut pandang yang baru. Kami menganalisis kualitas udara berbasis PM10 dengan tujuan memprediksi tingkat PM10 di Jakarta dan menghasilkan rekomendasi-rekomendasi yang baik dilakukan untuk mengurangi tingkat PM10 tersebut.

## METODOLOGI

### A. Teori Pendukung

Model SARIMA (Seasonal ARIMA) merupakan salah satu model untuk merepresentasikan data deret waktu yang memiliki perilaku musiman yang kuat. Perilaku musiman dapat diartikan sebagai sebuah pola perubahan yang tetap dan berulang selama periode waktu  $S$ , di mana  $S$  didefinisikan sebagai periode waktu sampai pola berulang kembali. Dalam model ARIMA musiman, model AR musiman memprediksi  $Y_t$  menggunakan nilai data pada lag dengan kelipatan  $S$  (rentang musiman), sedangkan model MA musiman memprediksi  $y_t$  menggunakan *error* dengan lag yang merupakan kelipatan  $S$ .

Perilaku musiman pun seringkali menyebabkan data menjadi tidak stasioner. Oleh karena itu, dilakukan diferensiasi musiman (*seasonal differencing*) yang didefinisikan sebagai selisih antara nilai variabel dengan nilai variabel pada lag kelipatan  $S$ .

Model SARIMA menggabungkan faktor nonmusiman dan musiman dalam model multiplikatif. Notasi yang digunakan untuk model ini adalah sebagai berikut.

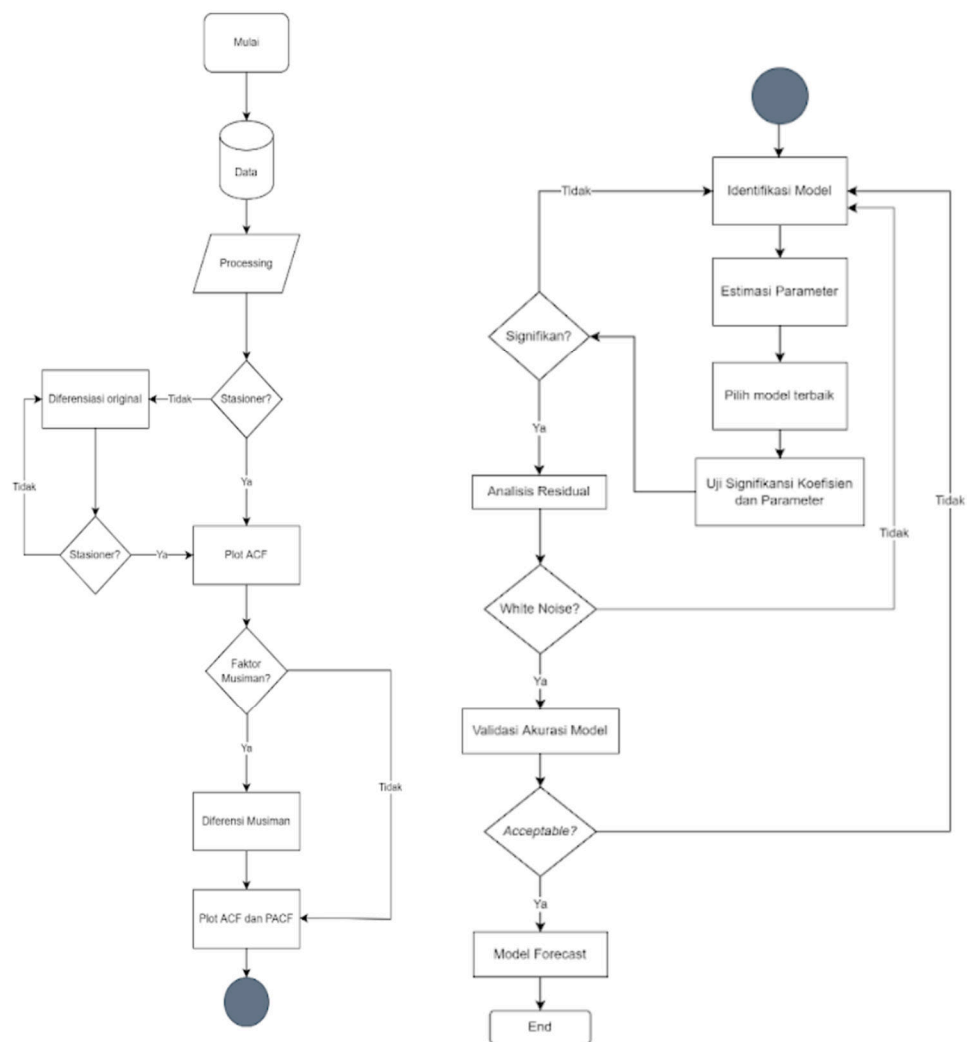
$$SARIMA(p, d, q) \times (P, D, Q)_S$$

Dengan keterangan dari persamaan tersebut sebagai berikut.

1.  $p$  = orde dari model AR
2.  $d$  = orde diferensiasi nonmusiman
3.  $q$  = orde dari model MA
4.  $P$  = orde dari model AR musiman
5.  $D$  = orde diferensiasi musiman
6.  $Q$  = orde dari model MA musiman
7.  $S$  = rentang musiman

### B. Tahapan Penelitian

Berikut merupakan diagram alir dari langkah-langkah penelitian.



**GAMBAR 1.** *Flowchart Penelitian*

## BAHAN DAN DATA

### *Lokasi Penelitian*

Data diperoleh dari Data Indeks Standar Pencemaran Udara (ISPU) di DKI Jakarta tahun 2010 hingga 2021, didapat dari <https://data.jakarta.go.id/>. Lokasi penelitian dari data yang digunakan adalah DKI Jakarta, khususnya Bundaran HI, Kelapa Gading, Jagakarsa, dan Lubang Buaya. Ruang lingkup data.

### *Ruang Lingkup Data*

Penelitian ini mengambil objek penelitian variabel PM10 pada Indeks Standar Pencemaran Udara (ISPU) di DKI Jakarta yang terdiri dari 4 stasiun. Adapun stasiun yang dimaksud adalah sebagai berikut.

1. DKI1 adalah daerah Bundaran HI (Jakarta Pusat).
2. DKI2 adalah daerah Kelapa Gading (Jakarta Utara).
3. DKI3 adalah daerah Jagakarsa (Jakarta Utara).
4. DKI4 adalah daerah Lubang Buaya (Jakarta Timur).

### Data Primer

Berikut adalah cuplikan data mentah PM10 yang merupakan data keseluruhan per hari yang diperoleh dari <https://data.jakarta.go.id/>.

TABEL 1. Cuplikan Data Mentah

tanggal	stasiun	PM10	SO2	CO	O3	NO2	max	critical	categori
2016-01-01	DKI1 (Bunderan HI)	59	19	27	31	1	59	PM10	SEDANG
2016-01-02	DKI1 (Bunderan HI)	52	19	---	33	2	52	PM10	SEDANG
2016-01-03	DKI1 (Bunderan HI)	44	19	---	36	2	44	PM10	BAIK
2016-01-04	DKI1 (Bunderan HI)	58	21	---	46	5	58	PM10	SEDANG
2016-01-05	DKI1 (Bunderan HI)	70	19	---	41	4	70	PM10	SEDANG
2016-01-06	DKI1 (Bunderan HI)	69	19	---	19	4	69	PM10	SEDANG

Berikut adalah cuplikan data bersih, data bersih yang digunakan merupakan rata-rata per bulan dari data mentah.

TABEL 2. Cuplikan Data Bersih

bulan/tahun	PM10	SO2	CO	O3	NO2	max
01/2010	44	4.871	34.129	20.903	13.903	44.645
02/2010	53.643	5.964	40.571	38.607	17.786	57.929
03/2010	53.032	7.742	37.806	41.387	18.548	57.903
04/2010	52	6.167	34.233	38.5	17.833	56.267
05/2010	52.032	14.839	36.677	52.613	19.194	65.452
06/2010	57.333	16.867	40.467	38.533	19.633	62.2

Dengan keterangan sebagai berikut.

1. Tanggal : Tanggal pengukuran kualitas udara.
2. Stasiun : Lokasi pengukuran di stasiun (DKI1-DKI4).
3. PM10 : Partikulat salah satu parameter yang diukur.
4. SO2 : Sulfida (dalam bentuk SO2) salah satu parameter yang diukur.
5. CO : Karbon Monoksida salah satu parameter yang diukur.
6. O3 : Ozon salah satu parameter yang diukur.
7. NO2 : Nitrogen dioksida salah satu parameter yang diukur.
8. max : Nilai ukur paling tinggi seluruh parameter dalam waktu yang sama

### Sumber Data

Penelitian ini menggunakan data yang diperoleh dari suatu *website* yang menyediakan beragam jenis data dan dapat diakses secara bebas. Data yang digunakan dalam penelitian ini diperoleh dari <https://data.jakarta.go.id/>. Adapun yang menjadi sumber data primer dalam penelitian ini adalah konsentrasi PM10 pada Indeks Standar Pencemaran Udara (ISPU) di DKI Jakarta tahun 2010 hingga 2021.

### Variabel Penelitian

Variabel yang difokuskan untuk diteliti pada penelitian kali ini adalah PM10. Hasil pengolahan data dari konsentrasi PM10 ini dapat dipengaruhi oleh konsentrasi PM10 di masa sebelumnya dan galat.

### Teknik Pengumpulan Data

Untuk memperoleh data yang dikehendaki sesuai dengan permasalahan dalam penelitian ini menggunakan metode angket dengan melakukan observasi terhadap konsentrasi PM10 pada Indeks Standar Pencemaran Udara (ISPU) di DKI Jakarta tahun 2010 hingga 2021.

## METODE PENELITIAN

### A. Autocorrelation Function (ACF)

Fungsi Autokorelasi atau yang lebih dikenal dengan ACF merupakan koefisien korelasi antara  $Y_t$  dan  $Y_{t-k}$  pada lag ke k. ACF biasanya dinotasikan dengan  $\rho_k$  dan didefinisikan sebagai berikut. (Wei, 2006)

$$\rho_k = \frac{Cov(Y_t, Y_{t-k})}{\sqrt{Var(Y_t)Var(Y_{t-k})}} = \frac{Cov(Y_t, Y_{t-k})}{Var(Y_t)} = \frac{\gamma_k}{\gamma_0}$$

### B. Partial Autocorrelation Function (PACF)

Fungsi Autokorelasi Parsial atau PACF merupakan sebuah fungsi dari ACF yang digunakan untuk menentukan orde p dari model AR. Pada analisis deret waktu, PACF dinotasikan dengan  $\phi_{kk}$  dengan persamaan sebagai berikut. (Wei, 2006)

$$\hat{\phi}_{k+1,k+1} = \frac{\hat{\rho}_{k+1} - \sum_{j=1}^k \hat{\phi}_{kj} \hat{\rho}_{k+1-j}}{1 - \sum_{j=1}^k \hat{\phi}_{kj} \hat{\rho}_j}$$

Dengan keterangan sebagai berikut.

$\hat{\rho}_k$  : sample ACF lag-k

$\hat{\phi}_{kk}$  : sample ACF lag-k

### C. Uji Kestasioneran: Uji Augmented Dickey-Fuller (ADF)

Uji Augmented Dickey-Fuller (ADF) memasukkan adanya autokorelasi di dalam variabel gangguan dengan memasukkan variabel independen berupa kelambanan diferensi. Hipotesis uji stasioner data deret waktu menggunakan ADF adalah:

$H_0$ : data tidak stasioner

$H_1$ : data stasioner

### D. Uji Diagnostik: Uji Ljung-Box

Uji Ljung-Box digunakan untuk menguji independensi residual antar lag pada model. Hipotesis yang digunakan adalah:

$H_0$ : residual saling bebas

$H_1$ : residual tidak saling bebas

### E. Uji Diagnostik: Uji Kolmogorov-Smirnov

Uji Kolmogorov-Smirnov menggunakan perbandingan distribusi data yang akan diuji normalitasnya dengan distribusi normal baku. Hipotesis yang digunakan dalam uji ini adalah:

$H_0$ : residual berdistribusi normal

$H_1$ : residual tidak berdistribusi normal


### F. Uji Heteroskedastik

Uji heteroskedastisitas bertujuan menguji apakah dalam model regresi terjadi ketidaksamaan varians dari residual satu pengamatan ke pengamatan yang lain. Hipotesis yang digunakan dalam uji heteroskedastik adalah:

$H_0$ : tidak ada efek ARCH  
 $H_1$ : terdapat efek ARCH

## HASIL DAN PEMBAHASAN

Berdasarkan Gambar 2 dapat dilihat bahwa konsentrasi PM10 di DKI Jakarta dari Januari 2010 hingga Oktober 2021 mengalami fluktuasi. Dari statistika deskriptif terlihat bahwa rata-rata konsentrasi PM10 adalah  $64.17 \mu\text{gr}/\text{m}^3$  yang tergolong tingkat kualitas udara menengah (sedang). Di sisi lain, kenyataannya konsentrasi PM10 minimum bernilai  $30.48 \mu\text{gr}/\text{m}^3$  dan maksimum bernilai  $110.06 \mu\text{gr}/\text{m}^3$ . Dapat dilihat bahwa jangkauan konsentrasi PM10 cukup besar.




**GAMBAR 2.** Line Chart Konsentrasi PM10 di DKI Jakarta Tahun 2010-2021


**TABEL 3.** Sari Numerik Data

Min	Q1	Median	Mean	Q3	Max	Std. Dev.
30.48	54.57	63.06	64.17	71.87	110.06	14.478


Kemudian, dari plot ACF data pada Gambar 3 terlihat bahwa nilai ACF signifikan pada lag kelipatan enam. Hal tersebut menunjukkan adanya pola musiman dengan periode enam bulan yang bersesuaian dengan musim kemarau dan musim hujan di Indonesia. Pola musiman ini terlihat juga pada subseries plot pada Gambar 4 dan plot dekomposisi pada Gambar 5.



**GAMBAR 3.** Grafik ACF Data




**GAMBAR 4.** Grafik Data Setiap Musim (*Subseries Plot*)



**GAMBAR 5.** Dekomposisi Data

Data yang kami gunakan memiliki 142 observasi yang berarti ada sekitar 12 tahun data konsentrasi PM10. Dengan demikian, terdapat sebanyak  $0.8 \times 12 \text{ tahun} \approx 9.5 \text{ tahun} = 114$  observasi dan sisa

datanya akan menjadi data validation. Terlihat bahwa ACF data *training* pada Gambar 6 masih memiliki pola musiman sehingga dilakukan diferensiasi musiman. Kemudian, uji ADF pada data diferensiasi musiman tersebut menghasilkan nilai  $p$  – *value* sebesar 0.01 sehingga dapat disimpulkan bahwa data telah stasioner.



**GAMBAR 6.** Grafik ACF Data *Training*

Dari plot ACF dan PACF diferensiasi musiman kami menduga model yang cocok adalah sebagai berikut.

1.  $SARIMA(0,0,2) \times (1,1,0)_6$
2.  $SARIMA(1,0,0) \times (1,1,0)_6$
3.  $SARIMA(1,0,2) \times (1,1,0)_6$

Kemudian, diperoleh nilai AIC dari setiap model tersebut sebagai berikut.

**TABEL 4.** AIC Setiap Model

MODEL	AIC
$SARIMA(0,0,2) \times (1,1,0)_6$	826.77
$SARIMA(1,0,2) \times (1,1,0)_6$	808.01
$SARIMA(1,0,0) \times (1,1,0)_6$	804.47
$ARIMA(2,0,0)$ (Cara Otomatis)	836.56

Dapat dilihat bahwa model dengan AIC terkecil dimiliki oleh model  $SARIMA(1,0,0) \times (1,1,0)_6$  sehingga akan dipilih model  $SARIMA(1,0,0) \times (1,1,0)_6$  untuk dianalisis lebih lanjut. Berikutnya, akan dilakukan uji signifikansi dari model.

**z test of coefficients:**

```

      Estimate Std. Error z value Pr(>|z|)
ar1    0.793308   0.058509  13.559 < 2.2e-16 ***
sar1   -0.739606   0.059864 -12.355 < 2.2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```



**GAMBAR 7.** Hasil Uji Signifikansi Parameter

Dapat dilihat bahwa semua parameter signifikan sehingga dapat disimpulkan bahwa model yang dipilih dapat digunakan untuk memodelkan data. Berikutnya, akan dilihat performa model.

	ME	RMSE	MAE	MPE	MAPE	MASE	ACF1
Training set	0.2283871	9.259311	7.06156	-0.8839814	11.46901	0.8899227	-0.01361112

**GAMBAR 8.** Nilai Galat dari Model

Dapat dilihat bahwa RMSE dari model sebesar 9.259 yang sangat kecil dibandingkan dengan standar deviasi data. Diperoleh juga nilai MAPE sebesar 11.47%. Jadi, dapat disimpulkan bahwa model ini cocok digunakan untuk memodelkan data yang ada.

Selanjutnya, dilakukan uji diagnostik pada model. Diperoleh bahwa uji Ljung-Box menghasilkan  $p - value$  sebesar 0.3664 yang lebih besar dari alpha untuk  $\alpha = 0.05$  sehingga dapat disimpulkan bahwa data saling bebas. Hal ini juga diperkuat dari plot ACF yang tidak signifikan. Dapat dilihat juga bahwa distribusi dari residual hampir menyerupai distribusi normal dan plot residual terlihat memiliki rata-ran nol dan variansi yang konstan.


Kemudian, kami melakukan uji Kolmogorov-Smirnov dengan hipotesis

$H_0$ : data berdistribusi normal

$H_1$ : data tidak berdistribusi normal

Diperoleh  $p - value = 0.9535 > \alpha = 0.05$  maka  $H_0$  tidak ditolak dan dapat disimpulkan bahwa residual model berdistribusi normal.

Selanjutnya, kami juga melakukan uji ARCH-LM dan memperoleh  $p - value = 0.3587 > \alpha = 0.05$  sehingga dapat disimpulkan bahwa data tidak perlu dimodelkan dengan model heteroskedastik. Hal ini didukung pula oleh variansi galat yang terlihat konstan pada plot galat.



**GAMBAR 9.** Plot Residual


Dengan demikian, dipilih model  $SARIMA(1,0,0) \times (1,1,0)_6$  dengan persamaan

$$Y_t = 0.799Y_{t-1} + 0.261Y_{t-6} + 0.532Y_{t-7} - 0.586Y_{t-13} + e_t$$

yang menunjukkan bahwa konsentrasi PM10 bulan ini dipengaruhi nilai konsentrasi PM10 satu, enam, tujuh, dan tiga belas bulan sebelumnya.

Sebelum dilakukan prakiraan, kami menguji performa model untuk memodelkan data validasi dan didapat nilai RMSE sebesar 8.7389 yang lebih kecil dari RMSE yang diperoleh sebelumnya, yaitu 9.2593. Kemudian, diperoleh juga MAPE sebesar 11.578% yang tidak berbeda jauh dari MAPE yang diperoleh sebelumnya, yaitu 11.469%.

Berikutnya, dilakukan prakiraan untuk 4 musim ke depan (atau 2 tahun ke depan) dengan model  $SARIMA(1,0,0) \times (1,1,0)_6$  dan diperoleh grafik prakiraan sebagai berikut.



**GAMBAR 10.** Grafik *Forecasting* Konsentrasi PM10 di DKI Jakarta

Lebih lanjut, dengan menggunakan cara serupa, kami memodelkan data untuk setiap stasiun tempat partikulat udara diukur dan memperoleh model yang sesuai untuk setiap stasiun sebagai berikut.

STASIUN DKI1: Bundaran HI (Jakarta Pusat) -  $SARIMA(1,0,0) \times (1,1,0)_6$

$$PM10_{DKI1,t} = 0.586PM10_{DKI1,t-1} - 0.363PM10_{DKI1,t-6} + 0.425PM10_{DKI1,t-7} - 0.374PM10_{DKI1,t-13} + e_t$$

STASIUN DKI2: Kelapa Gading (Jakarta Utara) -  $SARIMA(1,0,0) \times (1,1,0)_6$

$$PM10_{DKI2,t} = 0.780PM10_{DKI2,t-1} - 0.191PM10_{DKI2,t-6} + 0.660PM10_{DKI2,t-7} - 0.631PM10_{DKI2,t-13} + e_t$$


STASIUN DKI3: Jagakarsa (Jakarta Utara) -  $SARIMA(1,0,0) \times (0,1,1)_6$

$$PM10_{DKI3,t} = 0.727PM10_{DKI3,t-1} + PM10_{DKI3,t-6} - 0.727PM10_{DKI3,t-7} + e_t + 0.729e_{t-6}$$


STASIUN DKI4: Lubang Buaya (Jakarta Timur) -  $SARIMA(1,0,0) \times (1,1,0)_6$

$$PM10_{DKI4,t} = 0.689PM10_{DKI4,t-1} - 0.206PM10_{DKI4,t-6} + 0.652PM10_{DKI4,t-7} - 0.547PM10_{DKI4,t-13} + e_t$$


Perhatikan bahwa model DKI1, DKI2, dan DKI4 dipengaruhi oleh konsentrasi PM10 1 musim (6 bulan) sebelumnya. Sementara itu, model DKI3 dipengaruhi oleh galat 1 musim (6 bulan) sebelumnya. Kemudian, dengan melakukan prakiraan untuk 4 musim ke depan dengan hasil sebagai berikut.




DKI 1



DKI 2

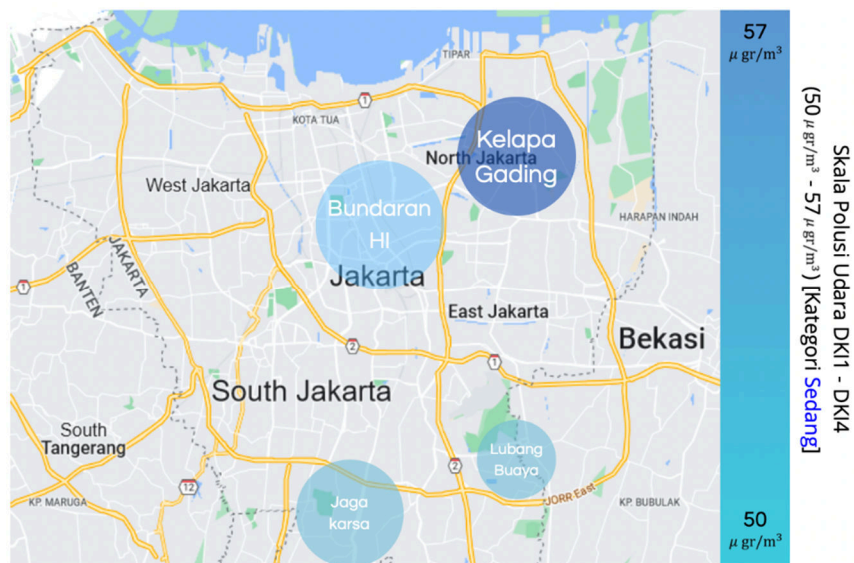


DKI 3



DKI 4


**GAMBAR 11.** Grafik *Forecasting* Konsentrasi PM10 di masing-masing Stasiun tempat pengukuran PM10



**GAMBAR 12.** Peta Polusi DKI Jakarta

## KESIMPULAN DAN SARAN

Dari hasil penelitian, diperoleh model yang cocok untuk memodelkan konsentrasi partikulat PM10 di DKI Jakarta adalah model  $SARIMA(1,0,0) \times (1,1,0)_6$  dengan hasil forecast pemodelan memiliki rata-rata sekitar  $50-57 \mu\text{gr}/\text{m}^3$ . Menurut klasifikasi pada [bmkg.go.id](http://bmkg.go.id), angka tersebut termasuk dalam klasifikasi sedang yang berarti tidak terlalu perlu dikhawatirkan namun kualitas udara tetap perlu ditingkatkan agar dalam jangka panjang tidak akan berkembang menjadi sebuah masalah yang serius.



GAMBAR 13. Peta Polusi di Setiap Stasiun DKI Jakarta yang Dipilih

## UCAPAN TERIMA KASIH

Terima kasih kepada dosen pengampu mata kuliah AK2281 Analisis Deret Waktu, Dr. Utriweni Mukhaiyar, S.Si., M.Si., serta asisten dosen yang membantu penelitian, membantu dalam diskusi, dan memberi masukan yang membangun dan membuat penelitian berjalan lebih baik.

## REFERENSI

- Cryer, J. D., & Chan, K. S. (2008). Time series analysis: with applications in R (Vol. 2). New York: Springer.
- Suryanto, D.A (2012). Analisis Tingkat Polusi Udara Terhadap Pengaruh Pertumbuhan Kendaraan Studi Kasus DKI Jakarta, Ejournal Gunadarma.
- Wei, W. W. (2006). Time series analysis. In The Oxford Handbook of Quantitative Methods in Psychology: Vol. 2.


## LAMPIRAN

### 1) Syntax pemodelan PM10 di DKI Jakarta

#### Library yang digunakan

```
# Untuk membaca data dengan format csv
library(readr)
# Untuk membersihkan data
library(tidyr)
# Untuk mengubah data menjadi Time Series,
# membuat plot ACF, plot PACF, Model ARIMA dan ADF Test
library(tseries)
# Untuk melihat signifikansi koefisien dari parameter
library(lmtest)
# Untuk memprediksi data dari model
library(forecast)
# Untuk melakukan uji heteroskedastik
library(FinTS)

# Memanggil Data
setwd("E:/Praktikum ADW")
library(readr)
data <- read_csv("ispu.csv", col_types = cols(tanggal = col_date(format = "%m/%Y")))
# Membuat grafik data
plot(data$tanggal, data$pm10, type = 'l', main = 'Konsentrasi PM10 di DKI Jakarta Tahun 2010-2021', xlab = "Tahun", ylab = "Konsentrasi PM10 ( $\mu\text{gr}/\text{m}^3$ ")
)
# Membuat garis rata-rata
abline(h=mean(data$pm10), lwd=2,
lty = 2, col = 'red')
```

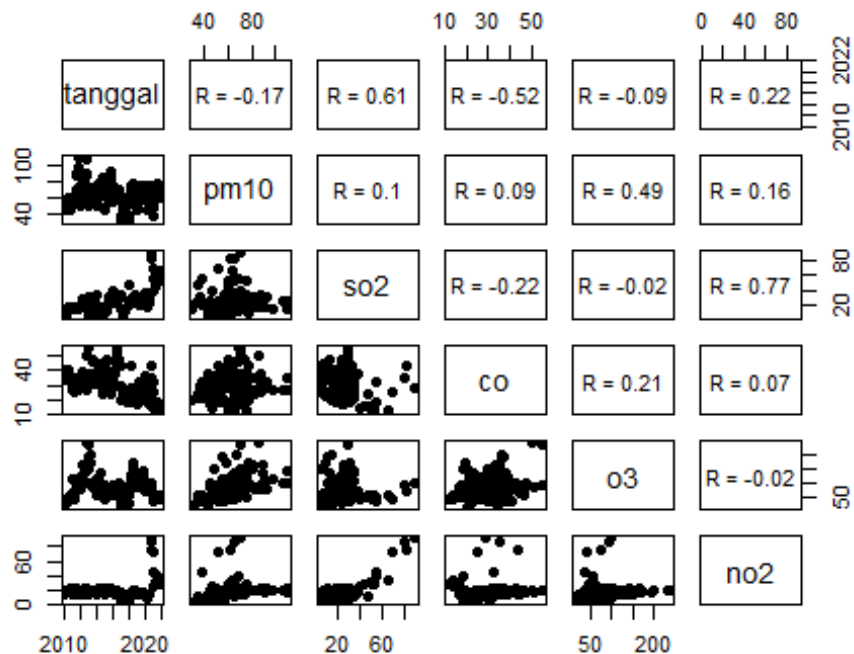


```
# Correlation panel
panel.cor <- function(x, y){
  usr <- par("usr"); on.exit(par(usr))
```

```

par(usr = c(0, 1, 0, 1))
r <- round(cor(x, y), digits=2)
txt <- paste0("R = ", r)
cex.cor <- 0.8/strwidth(txt)
text(0.5, 0.5, txt)
}
# Customize upper panel
lower.panel<-function(x, y){
  points(x,y, pch = 19)
}
# Create the plots
pairs(data[,1:6],
      lower.panel = lower.panel,
      upper.panel = panel.cor)

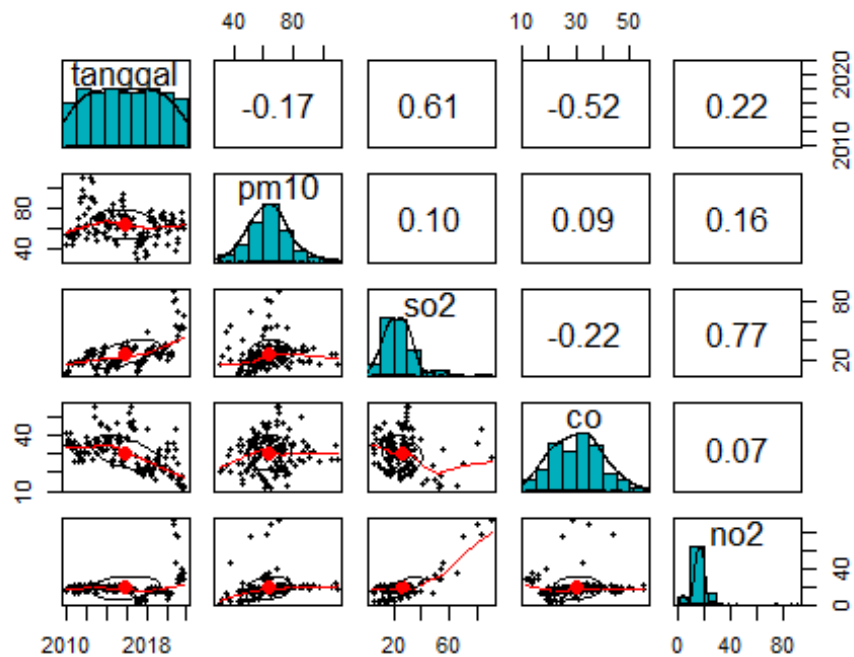
```



```

library(psych)
pairs.panels(data[, -5],
             method = "pearson", # correlation method
             hist.col = "#00AFBB",
             density = TRUE, # show density plots
             ellipses = TRUE # show correlation ellipses
)

```




```
summary(data$pm10)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##  30.48   54.57   63.06   64.17   71.87  110.06
```

```
sd(data$pm10)
```

```
## [1] 14.47786
```

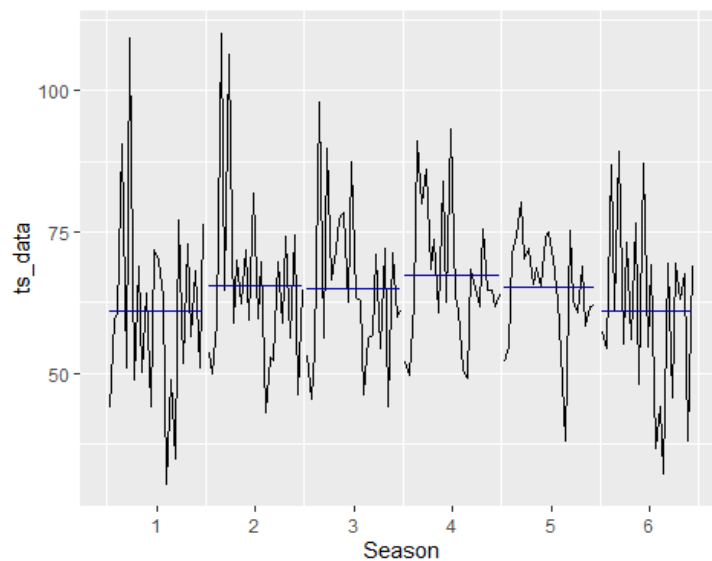
```
acf(data$pm10, lag = 48, main="Plot ACF Data")
```




Pada grafik ACF dapat dilihat bahwa nilai ACF setiap lag kelipatan 6 lebih tinggi dari yang lain sehingga akan diasumsikan bahwa data memiliki pola musiman dengan  $s = 6$

```
# Membuat data menjadi time series
ts_data <- ts(data$pm10, frequency = 6)
```

```
#Plot per subseries
ggsubseriesplot(ts_data)
```



```
plot(decompose(ts_data))
```



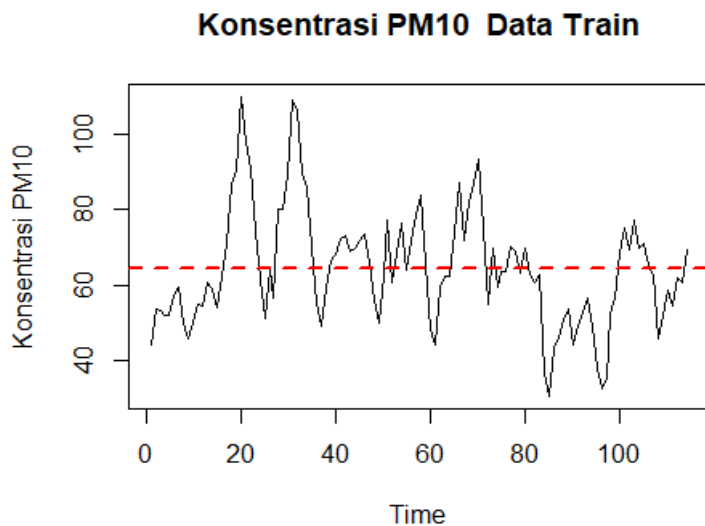
Pada data terdapat 142 observasi yang berarti terdapat sekitar 12 tahun. Dengan demikian, jumlah observasi yang akan menjadi data train adalah sebanyak  $0.8 \times 12 \text{ tahun} \approx 9.5 \text{ tahun} = 114$  observasi dan sisa datanya akan menjadi data validation

```
# Membuat data train dan validation dan mengubahnya menjadi data time series
pm10 <- ts(data$pm10)
# data yang akan digunakan untuk membuat model
pm10_train <- ts(pm10[1:114])
# data yang akan digunakan untuk memvalidasi model
pm10_validation <- ts(pm10[114:142])
```



## 2. Identifikasi Model

```
# Membuat grafik data
plot(pm10_train , type = 'l', main = 'Konsentrasi PM10 Data Train', ylab =
"Konsentrasi PM10")
# Membuat garis rataaan
abline(h=mean(pm10_train),lwd=2, lty = 2, col ='red')
```

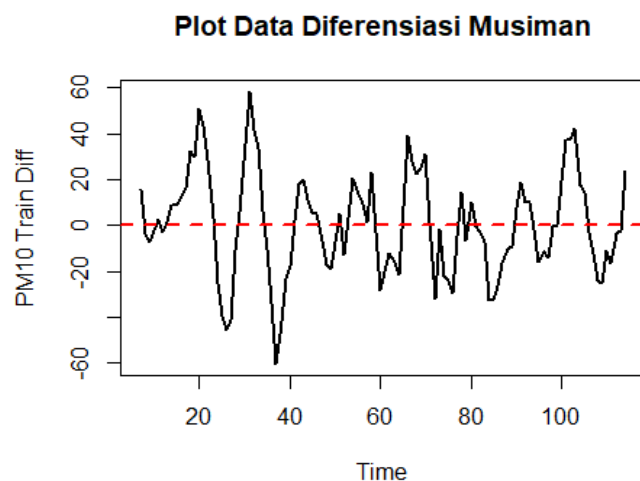


```
adf.test(pm10_train)


##
## Augmented Dickey-Fuller Test
##
## data: pm10_train
## Dickey-Fuller = -4.3767, Lag order = 4, p-value = 0.01
## alternative hypothesis: stationary
```

Diperoleh nilai  $p\text{-value} = 0.01 < \alpha = 0.05$  sehingga dapat disimpulkan bahwa data telah stasioner dalam rataaan. sehingga akan dilakukan diferensiasi musiman

```
pm10_train_diff <- diff(pm10_train, lag = 6)
plot(pm10_train_diff,lwd = 2,main = 'Plot Data Diferensiasi Musiman', ylab=
"PM10 Train Diff")
abline(h=mean(pm10_train_diff), lwd=2,lty = 2, col ='red')
```



```
acf(pm10_train, main = "Grafik ACF Data Train", lag.max = 36)
```




```
adf.test(pm10_train_diff)

## Warning in adf.test(pm10_train_diff): p-value smaller than printed p-value
##
## Augmented Dickey-Fuller Test
##
## data: pm10_train_diff
## Dickey-Fuller = -8.0834, Lag order = 4, p-value = 0.01
## alternative hypothesis: stationary


acf(pm10_train_diff, main = "Grafik ACF Data Diferensiasi Musiman", lag.max = 36)
```

**Grafik ACF Data Diferensiasi Musiman**



```
pacf(pm10_train_diff, main = "Grafik PACF Data Diferensiasi Musiman", lag.max = 49)
```

**Grafik PACF Data Diferensiasi Musiman**



Dari grafik-grafik tersebut dapat disimpulkan beberapa model yang akan dicoba, yaitu: 1.  $SARIMA(0,0,2) \times (1,1,0)_6$  2.  $SARIMA(1,0,0) \times (1,1,0)_6$  3.  $SARIMA(1,0,2) \times (1,1,0)_6$

### 3. PENAKSIRAN PARAMETER

```
mod_1 <- arima(pm10_train, order = c(0,0,2), seasonal = list(order = c(1,1,
0), period = 6),
               method = 'ML')
mod_1

##
## Call:
## arima(x = pm10_train, order = c(0, 0, 2), seasonal = list(order = c(1, 1
, 0),
##   period = 6), method = "ML")
##
## Coefficients:
##          ma1          ma2          sar1
##      0.7516    0.4231   -0.6666
```

```

## s.e.  0.0856  0.0895  0.0690
##
## sigma^2 estimated as 110.2:  log likelihood = -409.39,  aic = 826.77

mod_2 <- arima(pm10_train, order = c(1,0,0), seasonal = list(order = c(1,1,
0), period = 6),
               method = 'ML')
mod_2

##
## Call:
## arima(x = pm10_train, order = c(1, 0, 0), seasonal = list(order = c(1, 1
, 0),
##      period = 6), method = "ML")
##
## Coefficients:
##          ar1          sar1
##      0.7933  -0.7396
## s.e.  0.0585  0.0599
##
## sigma^2 estimated as 90.5:  log likelihood = -399.24,  aic = 804.47

mod_3 <- arima(pm10_train, order = c(1,0,2), seasonal = list(order = c(1,1,
0), period = 6),
               method = 'ML')
mod_3

##
## Call:
## arima(x = pm10_train, order = c(1, 0, 2), seasonal = list(order = c(1, 1
, 0),
##      period = 6), method = "ML")
##
## Coefficients:
##          ar1          ma1          ma2          sar1
##      0.7751  -0.0076  0.0750  -0.7384
## s.e.  0.0851  0.1284  0.1093  0.0629
##
## sigma^2 estimated as 90.09:  log likelihood = -399,  aic = 808.01

mod_auto = auto.arima(pm10_train, max.p=4,max.q=4, max.P = 4, max.Q = 4,sea
sonal =TRUE, stationary = FALSE)
mod_auto

## Series: pm10_train
## ARIMA(2,0,0) with non-zero mean
##
## Coefficients:
##          ar1          ar2          mean
##      0.9414  -0.1783  64.0954
## s.e.  0.0924  0.0925  3.5329
##
## sigma^2 estimated as 85.4:  log likelihood=-414.28
## AIC=836.56  AICc=836.93  BIC=847.5

```

Dapat dilihat bahwa model dengan AIC terkecil dimiliki oleh model  $SARIMA(1,0,0) \times (1,1,0)_6$  sehingga akan dipilih model  $SARIMA(1,0,0) \times (1,1,0)_6$  untuk dianalisis lebih lanjut. Berikutnya, akan dilakukan uji signifikansi dari model.

#### 4. Signifikansi dari Koefisien Parameter dan Pembuatan Model

```
coeftest(mod_2)
```

```
##
## z test of coefficients:
##
##      Estimate Std. Error z value Pr(>|z|)
## ar1    0.793308    0.058509  13.559 < 2.2e-16 ***
## sar1   -0.739606    0.059864 -12.355 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Dapat dilihat bahwa semua parameter signifikan sehingga dapat disimpulkan bahwa model yang dipilih dapat digunakan untuk memodelkan data. Berikutnya, akan dilihat performa model.


```
accuracy(mod_2)
```

```
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set 0.2283871 9.259311 7.06156 -0.8839814 11.46901 0.8899227
##              ACF1
## Training set -0.01361112
```

Dapat dilihat bahwa RMSE dari model sebesar 9.259 yang sangat kecil dibandingkan dengan standar deviasi data. Diperoleh juga nilai MAPE sebesar 11.47%. Jadi, dapat disimpulkan bahwa model ini cocok digunakan untuk memodelkan data yang ada.

#### 5. Uji Diagnostik

```
checkresiduals(mod_2)
```



```
##
##  Ljung-Box test
##
## data:  Residuals from ARIMA(1,0,0)(1,1,0)[6]
## Q* = 8.7204, df = 8, p-value = 0.3664
##
## Model df: 2.    Total lags used: 10
```

Perhatikan bahwa  $p\text{-value} > \alpha = 0.05$  sehingga dapat disimpulkan bahwa data saling bebas. Hal ini juga diperkuat dari plot ACF yang tidak signifikan. Dapat dilihat juga bahwa distribusi dari residual hampir menyerupai distribusi normal dan plot residual terlihat memiliki rata-rata nol dan variansi yang konstan.

```
data_residuals <- residuals(mod_2)
ks.test(residuals(mod_2), "pnorm", mean=mean(data_residuals), sd=sd(data_residuals))

##
##  One-sample Kolmogorov-Smirnov test
##
## data:  residuals(mod_2)
## D = 0.048233, p-value = 0.9535
## alternative hypothesis: two-sided
```

Uji Kolmogorov-Smirnov dengan hipotesis:

$H_0$ : data berdistribusi normal

$H_1$ : data tidak berdistribusi normal

Diperoleh  $p\text{-value} > \alpha = 0.05$  maka  $H_0$  tidak ditolak dan dapat disimpulkan bahwa residual model berdistribusi normal.

```
ArchTest(data_residuals)
```

```
##
## ARCH LM-test; Null hypothesis: no ARCH effects
##
## data: data_residuals
## Chi-squared = 13.144, df = 12, p-value = 0.3587
```

Karena  $p\text{-value} = 0.3587 > \alpha = 0.05$ , dapat disimpulkan bahwa data tidak perlu dimodelkan dengan model heteroskedastik. Hal ini didukung pula oleh variansi galat yang terlihat konstan pada plot galat.

## 5.1 Forecasting

Sebelum dilakukan forecasting, akan dilihat terlebih dahulu performa model untuk memodelkan data validation terlebih dahulu.

```
validation <- forecast(pm10_train,model=mod_2,h=length(pm10_validation))
actual <- as.vector(pm10_validation)
rmse_validation <- sqrt(mean((as.vector(validation$mean)-actual)^2))
rmse_validation

## [1] 8.738945
```

Dapat dilihat bahwa RMSE dari model  $\approx 8.7389$  yang lebih kecil daripada RMSE yang diperoleh sebelumnya. Dengan demikian, dapat disimpulkan bahwa model yang dipilih dapat digunakan untuk memprediksi data.

```
ape_validation <- abs((as.vector(validation$mean) -actual)/actual)*100
mape_validation <- mean(ape_validation)
mape_validation

## [1] 11.57768
```

Diperoleh juga MAPE sebesar  $\approx 11.578$  yang hampir sama dengan nilai MAPE yang diperoleh sebelumnya

```
fc <- forecast(pm10,model=mod_2, h=24)
summary(fc)

##
## Forecast method: ARIMA(1,0,0)(1,1,0)[6]
##
## Model Information:
## Series: object
## ARIMA(1,0,0)(1,1,0)[6]
##
## Coefficients:
##          ar1          sar1
##         0.7933        -0.7396
## s.e.    0.0000         0.0000
##
## sigma^2 estimated as 90.5:  log likelihood=-500.75
## AIC=1003.5   AICc=1003.53   BIC=1006.41
##
## Error measures:
```

	ME	RMSE	MAE	MPE	MAPE	MASE
##						

```
## Training set 0.1285096 9.221845 7.122363 -1.070013 11.76014 0.9265439
```

```
## ACF1
```

```
## Training set -0.09898477
```

```
##
```


```
## Forecasts:
```

##	Point	Forecast	Lo 80	Hi 80	Lo 95	Hi 95
## 143	61.89696	49.70552	74.08840	43.25177	80.54216	
## 144	46.17466	30.61284	61.73649	22.37490	69.97442	
## 145	57.65201	40.30156	75.00246	31.11679	84.18724	
## 146	51.03059	32.64347	69.41770	22.90993	79.15125	
## 147	60.34434	41.33378	79.35490	31.27020	89.41848	
## 148	62.30707	42.91443	81.69972	32.64858	91.96557	
## 149	62.10533	41.74161	82.46906	30.96171	93.24896	
## 150	62.96843	42.01663	83.92022	30.92542	95.01143	
## 151	71.54042	50.22684	92.85400	38.94412	104.13672	
## 152	61.15449	39.61635	82.69263	28.21475	94.09424	
## 153	60.81005	39.13177	82.48832	27.65598	93.96411	
## 154	63.53962	41.77361	85.30562	30.25138	96.82785	
## 155	61.95448	37.38738	86.52158	24.38235	99.52662	
## 156	50.55025	24.37354	76.72696	10.51643	90.58407	
## 157	61.27053	34.12973	88.41133	19.76226	102.77880	
## 158	53.66842	25.93807	81.39878	11.25851	96.07834	
## 159	60.46690	32.37186	88.56194	17.49924	103.43456	
## 160	62.62905	34.30690	90.95120	19.31406	105.94403	
## 161	62.06687	32.70331	91.43042	17.15919	106.97455	
## 162	59.73545	29.73503	89.73587	13.85376	105.61713	
## 163	68.86671	38.47232	99.26110	22.38251	115.35091	
## 164	59.20557	28.56584	89.84529	12.34615	106.06498	
## 165	60.72102	29.92789	91.51414	13.62700	107.81504	
## 166	63.30276	32.41349	94.19204	16.06170	110.54383	

```
plot(forecast(mod_2, h=24, level=c(80,95)), xaxt='n', ylab="Konsentrasi PM10 (µgr/m^3)", xlab="Bulan/Tahun")  
axis(1, at=seq(1, 150,10), labels=format(seq(as.Date("2010/1/1"), by = "year", length.out = 15),format("%b %Y")), cex.axis=0.8, xpd=TRUE)
```



### Forecasts from ARIMA(1,0,0)(1,1,0)[6]



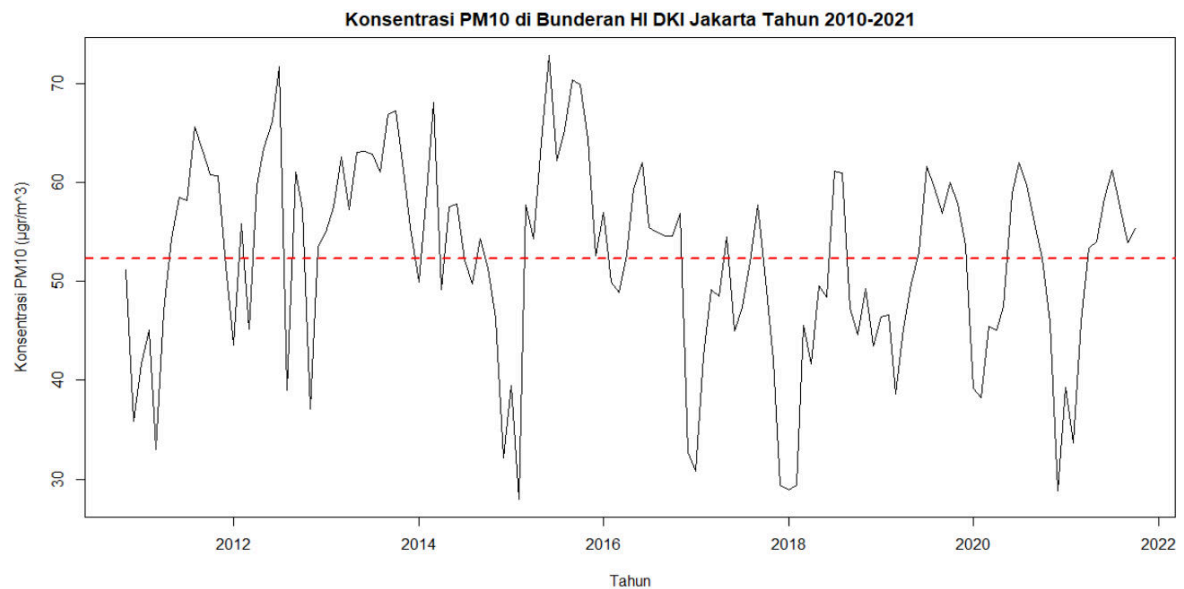
2) Syntax pemodelan PM10 di stasiun DKI 1

#### Library yang digunakan

```
# Untuk membaca data dengan format csv
library(readr)
# Untuk membersihkan data
library(tidyr)
# Untuk mengubah data menjadi Time Series,
# membuat plot ACF, plot PACF, Model ARIMA dan ADF Test
library(tseries)
# Untuk melihat signifikansi koefisien dari parameter
library(lmtest)
# Untuk memprediksi data dari model
library(forecast)
# Untuk melakukan uji heteroskedastik
library(FinTS)

# Memanggil Data
setwd("E:/Praktikum ADW")
library(readr)
data <- read_csv("ispu_stasiun.csv",
  col_types = cols(`bulan/tahun` = col_date(format = "%m/%Y"),
    `DKI 1` = col_number(), `DKI 2` = col_number(),
    `DKI 3` = col_number(), `DKI 4` = col_number()))
# Membuat grafik data
plot(data$`bulan/tahun`, data$`DKI 1`, type = 'l', main = 'Konsentrasi PM10
di Bunderan HI DKI Jakarta Tahun 2010-2021', xlab = "Tahun", ylab = "Konsen
trasi PM10 ( $\mu\text{gr}/\text{m}^3$ )")
# Membuat garis rata-rata
```

```
abline(h=mean(data$`DKI 1`),lwd=2,
lty = 2, col ='red')
```



```
summary(data$`DKI 1`)
```


```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##  28.00   45.89   53.98   52.27   59.50   72.85
```

```
sd(data$`DKI 1`)
```

```
## [1] 10.02104
```

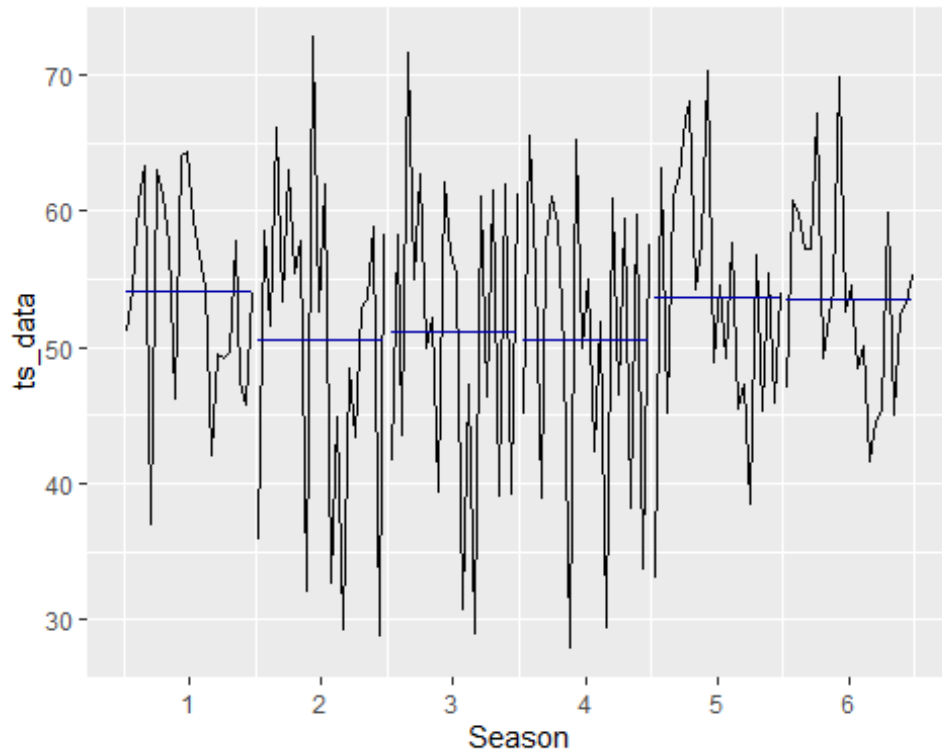
```
acf(data$`DKI 1`, lag = 48, main="Plot ACF Data")
```

### Plot ACF Data




Pada grafik ACF dapat dilihat bahwa nilai ACF setiap lag kelipatan 6 lebih tinggi dari yang lain sehingga akan diasumsikan bahwa data memiliki pola musiman dengan  $s = 6$

```
# Membuat data menjadi time series
ts_data <- ts(data$`DKI 1`, frequency = 6)
#Plot per subseries
ggsubseriesplot(ts_data)
```



```
plot(decompose(ts_data))
```

## Decomposition of additive time series




Pada data terdapat 132 observasi yang berarti terdapat 11 tahun. Dengan demikian, jumlah observasi yang akan menjadi data train adalah sebanyak  $0.8 \times 11 \text{ tahun} \approx 9 \text{ tahun} = 108$  observasi dan sisa datanya akan menjadi data validation

```
# Membuat data train dan validation dan mengubahnya menjadi data time series
pm10 <- ts(data$`DKI 1`)
# data yang akan digunakan untuk membuat model
pm10_train <- ts(pm10[1:108])
# data yang akan digunakan untuk memvalidasi model
pm10_validation <- ts(pm10[108:132])
```

## 2. Identifikasi Model

```
# Membuat grafik data
plot(pm10_train, type = 'l', main = 'Konsentrasi PM10 Data Train', ylab = "Konsentrasi PM10")
# Membuat garis rata-rata
abline(h=mean(pm10_train), lwd=2, lty = 2, col = 'red')
```

### Konsentrasi PM10 Data Train



```
adf.test(pm10_train)
```

```
## Warning in adf.test(pm10_train): p-value smaller than printed p-value
```

```
##
```

```
## Augmented Dickey-Fuller Test
```

```
##
```

```
## data: pm10_train
```

```
## Dickey-Fuller = -4.6338, Lag order = 4, p-value = 0.01
```

```
## alternative hypothesis: stationary
```


Diperoleh nilai p-value =  $0.01 < \alpha = 0.05$  sehingga dapat disimpulkan bahwa data telah stasioner dalam rata-rata. sehingga akan dilakukan diferensiasi musiman

```
pm10_train_diff <- diff(pm10_train, lag = 6)
```

```
plot(pm10_train_diff, lwd = 2, main = 'Plot Data Diferensiasi Musiman', ylab =  
"PM10 Train Diff")
```

```
abline(h = mean(pm10_train_diff), lwd = 2, lty = 2, col = 'red')
```

### Plot Data Diferensiasi Musiman




```
adf.test(pm10_train_diff)

## Warning in adf.test(pm10_train_diff): p-value smaller than printed p-value
##
## Augmented Dickey-Fuller Test
##
## data: pm10_train_diff
## Dickey-Fuller = -5.7281, Lag order = 4, p-value = 0.01
## alternative hypothesis: stationary


acf(pm10_train_diff, main = "Grafik ACF Data Diferensiasi Musiman", lag.max = 36)
```

**Grafik ACF Data Diferensiasi Musiman**



```
pacf(pm10_train_diff, main = "Grafik PACF Data Diferensiasi Musiman", lag.max = 49)
```

**Grafik PACF Data Diferensiasi Musiman**



Dari grafik-grafik tersebut dapat disimpulkan beberapa model yang akan dicoba, yaitu: 1.  $SARIMA(0,0,2) \times (1,1,0)_6$  2.  $SARIMA(1,0,0) \times (1,1,0)_6$  3.  $SARIMA(1,0,2) \times (1,1,0)_6$

### 3. PENAKSIRAN PARAMETER

```
mod_1 <- arima(pm10_train, order = c(0,0,2), seasonal = list(order = c(1,1,
0), period = 6),
               method = 'ML')
mod_1

##
## Call:
## arima(x = pm10_train, order = c(0, 0, 2), seasonal = list(order = c(1, 1
, 0),
##      period = 6), method = "ML")
##
## Coefficients:
##          ma1      ma2      sar1
##      0.4412  0.2355 -0.6283
## s.e.  0.1104  0.1194  0.0778
##
## sigma^2 estimated as 90.5:  log likelihood = -376.15,  aic = 760.3

mod_2 <- arima(pm10_train, order = c(1,0,0), seasonal = list(order = c(1,1,
0), period = 6),
               method = 'ML')
mod_2

##
## Call:
## arima(x = pm10_train, order = c(1, 0, 0), seasonal = list(order = c(1, 1
, 0),
##      period = 6), method = "ML")
##
## Coefficients:
##          ar1      sar1
##      0.5864 -0.6368
## s.e.  0.0811  0.0740
##
## sigma^2 estimated as 83.42:  log likelihood = -372.09,  aic = 750.18

mod_3 <- arima(pm10_train, order = c(1,0,2), seasonal = list(order = c(1,1,
0), period = 6),
               method = 'ML')
mod_3

##
## Call:
## arima(x = pm10_train, order = c(1, 0, 2), seasonal = list(order = c(1, 1
, 0),
##      period = 6), method = "ML")
##
## Coefficients:
##          ar1      ma1      ma2      sar1
##      0.6975 -0.2282  0.1056 -0.6450
## s.e.  0.1281  0.1474  0.1413  0.0759
##
## sigma^2 estimated as 81.1:  log likelihood = -370.71,  aic = 751.42
```



```

mod_auto = auto.arima(pm10_train, max.p=4,max.q=4, max.P = 4, max.Q = 4,seasonal =TRUE, stationary = FALSE)
mod_auto

## Series: pm10_train
## ARIMA(1,0,0) with non-zero mean
##
## Coefficients:
##          ar1      mean
##      0.5998  52.8261
## s.e.  0.0761   1.9168
##
## sigma^2 estimated as 66.54: log likelihood=-379.14
## AIC=764.28   AICc=764.51   BIC=772.33

```

Dapat dilihat bahwa model dengan AIC terkecil dimiliki oleh model  $SARIMA(1,0,0) \times (1,1,0)_6$  sehingga akan dipilih model  $SARIMA(1,0,0) \times (1,1,0)_6$  untuk dianalisis lebih lanjut. Berikutnya, akan dilakukan uji signifikansi dari model.

#### 4. Signifikansi dari Koefisien Parameter dan Pembuatan Model

```

coeftest(mod_2)

##
## z test of coefficients:
##
##      Estimate Std. Error z value Pr(>|z|)
## ar1    0.586425   0.081094  7.2315 4.778e-13 ***
## sar1   -0.636769   0.073964 -8.6092 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

Dapat dilihat bahwa semua parameter signifikan sehingga dapat disimpulkan bahwa model yang dipilih dapat digunakan untuk memodelkan data. Berikutnya, akan dilihat performa model.

```

accuracy(mod_2)

##              ME      RMSE      MAE      MPE      MAPE      MASE
ACF1
## Training set 0.3894066 8.87588 6.503669 -1.572567 13.3971 0.9690168 -0.08258947

```


Dapat dilihat bahwa RMSE dari model sebesar 8.876 yang sangat kecil dibandingkan dengan standar deviasi data (= 10.021). Jadi, dapat disimpulkan bahwa model ini cocok digunakan untuk memodelkan data yang ada.

#### 5. Uji Diagnostik

```

checkresiduals(mod_2)

```



```
##
##  Ljung-Box test
##
## data:  Residuals from ARIMA(1,0,0)(1,1,0)[6]
## Q* = 21.208, df = 8, p-value = 0.006616
##
## Model df: 2.    Total lags used: 10
```

Perhatikan bahwa  $p\text{-value} > \alpha = 0.05$  sehingga dapat disimpulkan bahwa data saling bebas. Hal ini juga diperkuat dari plot ACF yang tidak signifikan. Dapat dilihat juga bahwa distribusi dari residual hampir menyerupai distribusi normal dan plot residual terlihat memiliki rata-rata nol dan variansi yang konstan.

```
data_residuals <- residuals(mod_2)
ks.test(residuals(mod_2), "pnorm", mean=mean(data_residuals), sd=sd(data_residuals))

##
##  One-sample Kolmogorov-Smirnov test
##
## data:  residuals(mod_2)
## D = 0.11247, p-value = 0.1301
## alternative hypothesis: two-sided
```

Uji Kolmogorov-Smirnov dengan hipotesis:

$H_0$ : data berdistribusi normal

$H_1$ : data tidak berdistribusi normal

Diperoleh  $p\text{-value} = 0.1301 > \alpha = 0.05$  maka  $H_0$  tidak ditolak dan dapat disimpulkan bahwa residual model berdistribusi normal.

```
ArchTest(data_residuals)
```

```
##
## ARCH LM-test; Null hypothesis: no ARCH effects
##
## data: data_residuals
## Chi-squared = 7.4467, df = 12, p-value = 0.8267
```

Karena  $p\text{-value} = 0.8267 > \alpha = 0.05$ , dapat disimpulkan bahwa data tidak perlu dimodelkan dengan model heteroskedastik. Hal ini didukung pula oleh variansi galat yang terlihat konstan pada plot galat.

## 5.1 Forecasting

Sebelum dilakukan forecasting, akan dilihat terlebih dahulu performa model untuk memodelkan data validation terlebih dahulu.

```
validation <- forecast(pm10_train,model=mod_2,h=length(pm10_validation))
actual <- as.vector(pm10_validation)
rmse_validation <- sqrt(mean((as.vector(validation$mean)-actual)^2))
rmse_validation

## [1] 8.714455
```

Dapat dilihat bahwa RMSE dari model  $\approx 8.714$  yang lebih kecil daripada RMSE yang diperoleh sebelumnya. Dengan demikian, dapat disimpulkan bahwa model yang dipilih dapat digunakan untuk memprediksi data.

```
ape_validation <- abs((as.vector(validation$mean) -actual)/actual)*100
mape_validation <- mean(ape_validation)
mape_validation

## [1] 15.21531
```


Diperoleh juga MAPE sebesar  $\approx 15.215$

```
fc <- forecast(pm10,model=mod_2, h=24)
summary(fc)

##
## Forecast method: ARIMA(1,0,0)(1,1,0)[6]
##
## Model Information:
## Series: object
## ARIMA(1,0,0)(1,1,0)[6]
##
## Coefficients:
##          ar1      sar1
##       0.5864  -0.6368
## s.e.  0.0000   0.0000
##
## sigma^2 estimated as 83.42: log likelihood=-454.99
## AIC=911.99   AICc=912.02   BIC=914.82
##
## Error measures:
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set 0.2179156 8.627932 6.351321 -1.924762 13.39272 0.9791167
```

```
##                               ACF1
## Training set -0.06640536
##
## Forecasts:
##      Point Forecast      Lo 80      Hi 80      Lo 95      Hi 95
## 133      50.41776 38.71309 62.12242 32.51702 68.31850
## 134      40.50198 26.93318 54.07078 19.75029 61.25367
## 135      47.80290 33.64965 61.95614 26.15738 69.44842
## 136      42.69088 28.34215 57.03962 20.74639 64.63538
## 137      49.00719 34.59184 63.42254 26.96082 71.05356
## 138      54.15273 39.71455 68.59091 32.07143 76.23403
## 139      52.78366 37.59120 67.97611 29.54880 76.01851
## 140      51.89402 36.45069 67.33736 28.27549 75.51256
## 141      56.37248 40.84381 71.90115 32.62343 80.12154
## 142      52.16444 36.60653 67.72235 28.37067 75.95821
## 143      52.15142 36.58346 67.71937 28.34229 75.96055
## 144      54.91640 39.34500 70.48781 31.10199 78.73081
## 145      51.27975 33.19883 69.36066 23.62737 78.93212
## 146      44.64146 25.77451 63.50840 15.78696 73.49596
## 147      50.91654 31.78674 70.04633 21.66004 80.17303
## 148      46.13250 26.91314 65.35186 16.73903 75.52597
## 149      50.14958 30.89952 69.39964 20.70915 79.59001
## 150      54.43030 35.16969 73.69091 24.97374 83.88686
## 151      52.23750 31.95740 72.51759 21.22177 83.25323
## 152      49.25973 28.64068 69.87878 17.72562 80.79384
## 153      54.39075 33.65642 75.12508 22.68033 86.10117
## 154      49.97347 29.19965 70.74730 18.20265 81.74430
## 155      51.42430 30.63691 72.21169 19.63273 83.21587
## 156      54.73984 33.94779 75.53190 22.94114 86.53855
```

```
plot(forecast(mod_2, h=24, level=c(80,95)), xaxt='n', ylab="Konsentrasi PM10
(µgr/m^3)", xlab="Bulan/Tahun", main="Forecast SARIMA(1,0,0)(1,1,0)[6] untu
k Konsentrasi PM10 di Bunderan HI", asp=0.6)
axis(1, at=seq(1, 140, 10), labels=format(seq(as.Date("2010/1/1"), by = "yea
r", length.out = 14), format("%b %Y")), cex.axis=0.8, xpd=TRUE)
```




### 3) Syntax pemodelan PM10 di stasiun DKI 2

#### Library yang digunakan

```
# Untuk membaca data dengan format csv
library(readr)
# Untuk membersihkan data
library(tidyr)
# Untuk mengubah data menjadi Time Series,
# membuat plot ACF, plot PACF, Model ARIMA dan ADF Test
library(tseries)
# Untuk melihat signifikansi koefisien dari parameter
library(lmtest)
# Untuk memprediksi data dari model
library(forecast)
# Untuk melakukan uji heteroskedastik
library(FinTS)

# Memanggil Data
setwd("E:/Praktikum ADW")
library(readr)
data <- read_csv("ispu_stasiun.csv",
  col_types = cols(`bulan/tahun` = col_date(format = "%m/%Y"),
    `DKI 1` = col_number(), `DKI 2` = col_number(),
    `DKI 3` = col_number(), `DKI 4` = col_number()))
# Membuat grafik data
plot(data$`bulan/tahun`, data$`DKI 2`, type = 'l', main = 'Konsentrasi PM10
di Kelapa Gading Tahun 2010-2021', xlab = "Tahun", ylab = "Konsentrasi PM10
( $\mu\text{gr}/\text{m}^3$ )")
# Membuat garis rata-rata
abline(h=mean(data$`DKI 2`), lwd=2,
  lty = 2, col = 'red')
```




```
summary(data$`DKI 2`)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    15.26  48.85   57.79   55.40  65.14   75.71

sd(data$`DKI 2`)


## [1] 12.89014

acf(data$`DKI 2`, lag = 48, main="Plot ACF Data")
```




Pada grafik ACF dapat dilihat bahwa nilai ACF setiap lag kelipatan 6 lebih tinggi dari yang lain sehingga akan diasumsikan bahwa data memiliki pola musiman dengan  $s = 6$

```
# Membuat data menjadi time series
ts_data <- ts(data$`DKI 2`, frequency = 6)
#Plot per subseries
ggsubseriesplot(ts_data)
```



```
plot(decompose(ts_data))
```

### Decomposition of additive time series




Pada data terdapat 132 observasi yang berarti terdapat 11 tahun. Dengan demikian, jumlah observasi yang akan menjadi data train adalah sebanyak  $0.8 \times 11 \text{ tahun} \approx 9 \text{ tahun} = 114$  observasi dan sisa datanya akan menjadi data validation

```
# Membuat data train dan validation dan mengubahnya menjadi data time series
pm10 <- ts(data$`DKI 2`)
# data yang akan digunakan untuk membuat model
pm10_train <- ts(pm10[1:108])
# data yang akan digunakan untuk memvalidasi model
pm10_validation <- ts(pm10[108:132])
```

## 2. Identifikasi Model

```
# Membuat grafik data
plot(pm10_train, type = 'l', main = 'Konsentrasi PM10 Data Train', ylab =
"Konsentrasi PM10")
# Membuat garis rata-rata
abline(h=mean(pm10_train), lwd=2, lty = 2, col = 'red')
```



```
adf.test(pm10_train)

## Warning in adf.test(pm10_train): p-value smaller than printed p-value


##
## Augmented Dickey-Fuller Test
##
## data: pm10_train
## Dickey-Fuller = -5.9926, Lag order = 4, p-value = 0.01
## alternative hypothesis: stationary
```

Diperoleh nilai  $p\text{-value} = 0.01 < \alpha = 0.05$  sehingga dapat disimpulkan bahwa data telah stasioner dalam rata-rata. sehingga akan dilakukan diferensiasi musiman

```
pm10_train_diff <- diff(pm10_train, lag = 6)
plot(pm10_train_diff, lwd = 2, main = 'Plot Data Diferensiasi Musiman', ylab=
```



```
"PM10 Train Diff")
abline(h=mean(pm10_train_diff), lwd=2,lty = 2, col ='red')
```




```
adf.test(pm10_train_diff)

## Warning in adf.test(pm10_train_diff): p-value smaller than printed p-value

##
## Augmented Dickey-Fuller Test
##
## data: pm10_train_diff
## Dickey-Fuller = -8.489, Lag order = 4, p-value = 0.01
## alternative hypothesis: stationary


acf(pm10_train_diff, main = "Grafik ACF Data Diferensiasi Musiman", lag.max
= 36)
```

**Grafik ACF Data Diferensiasi Musiman**



```
pacf(pm10_train_diff, main = "Grafik PACF Data Diferensiasi Musiman", lag.max = 49)
```

**Grafik PACF Data Diferensiasi Musiman**



Dari grafik-grafik tersebut dapat disimpulkan beberapa model yang akan dicoba, yaitu: 1.  $SARIMA(0,0,2) \times (1,1,0)_6$  2.  $SARIMA(1,0,0) \times (1,1,0)_6$  3.  $SARIMA(1,0,1) \times (1,1,0)_6$  4.  $SARIMA(1,0,2) \times (1,1,0)_6$

### 3. PENAKSIRAN PARAMETER

```
mod_1 <- arima(pm10_train, order = c(0,0,2), seasonal = list(order = c(1,1,
0), period = 6),
               method = 'ML')
mod_1

##
## Call:
## arima(x = pm10_train, order = c(0, 0, 2), seasonal = list(order = c(1, 1
, 0),
##      period = 6), method = "ML")
##
## Coefficients:
##          ma1      ma2      sar1
##      0.5619  0.4358 -0.8033
## s.e.  0.0906  0.1089  0.0624
##
## sigma^2 estimated as 73.24:  log likelihood = -367.23,  aic = 742.46

mod_2 <- arima(pm10_train, order = c(1,0,0), seasonal = list(order = c(1,1,
0), period = 6),
               method = 'ML')
mod_2

##
## Call:
## arima(x = pm10_train, order = c(1, 0, 0), seasonal = list(order = c(1, 1
, 0),
##      period = 6), method = "ML")
##
## Coefficients:
##          ar1      sar1
##      0.7803 -0.8099
## s.e.  0.0713  0.0548
##
## sigma^2 estimated as 61.03:  log likelihood = -357.91,  aic = 721.82

mod_3 <- arima(pm10_train, order = c(1,0,1), seasonal = list(order = c(1,1,
0), period = 6),
               method = 'ML')
mod_3

##
## Call:
## arima(x = pm10_train, order = c(1, 0, 1), seasonal = list(order = c(1, 1
, 0),
##      period = 6), method = "ML")
##
## Coefficients:
##          ar1      ma1      sar1
##      0.9273 -0.3296 -0.8643
## s.e.  0.0610  0.1190  0.0500
##
## sigma^2 estimated as 56.47:  log likelihood = -354.82,  aic = 717.63
```

```

mod_4 <- arima(pm10_train, order = c(1,0,2), seasonal = list(order = c(1,1,
0), period = 6),
               method = 'ML')
mod_4

##
## Call:
## arima(x = pm10_train, order = c(1, 0, 2), seasonal = list(order = c(1, 1
, 0),
##      period = 6), method = "ML")
##
## Coefficients:
##          ar1          ma1          ma2          sar1
##      0.9076   -0.3391   0.0886   -0.8579
## s.e.  0.0738    0.1306   0.1139    0.0528
##
## sigma^2 estimated as 56.26:  log likelihood = -354.52,  aic = 719.05

mod_auto = auto.arima(pm10_train, max.p=4,max.q=4, max.P = 4, max.Q = 4,sea
sonal =TRUE, stationary = FALSE)
mod_auto

## Series: pm10_train
## ARIMA(2,0,1) with non-zero mean
##
## Coefficients:
##          ar1          ar2          ma1          mean
##      1.5584   -0.6896   -0.7487   55.4196
## s.e.  0.1557    0.1142    0.1732    1.6896
##
## sigma^2 estimated as 83.21:  log likelihood=-390.45
## AIC=790.91  AICc=791.49  BIC=804.32

```

Dapat dilihat bahwa model dengan AIC terkecil dimiliki oleh model  $SARIMA(1,0,1) \times (1,1,0)_6$  namun akan dipilih model  $SARIMA(1,0,0) \times (1,1,0)_6$  karena model ini menghasilkan galat validasi yang lebih kecil berdasarkan analisis lebih lanjut. Berikutnya, akan dilakukan uji signifikansi dari model.

#### 4. Signifikansi dari Koefisien Parameter dan Pembuatan Model

```

coeftest(mod_2)

##
## z test of coefficients:
##
##      Estimate Std. Error z value Pr(>|z|)
## ar1    0.780254    0.071269  10.948 < 2.2e-16 ***
## sar1  -0.809858    0.054791 -14.781 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

Dapat dilihat bahwa semua parameter signifikan sehingga dapat disimpulkan bahwa model yang dipilih dapat digunakan untuk memodelkan data. Berikutnya, akan dilihat performa model.


```
accuracy(mod_2)
```

```
##               ME      RMSE      MAE      MPE      MAPE      MASE  
ACF1  
## Training set 0.7523712 7.59177 5.976177 0.1943559 11.30042 0.7834028 -0.1917483
```

Dapat dilihat bahwa RMSE dari model sebesar 7.592 yang sangat kecil dibandingkan dengan standar deviasi data (= 12.89). Jadi, dapat disimpulkan bahwa model ini cocok digunakan untuk memodelkan data yang ada.

## 5. Uji Diagnostik

```
checkresiduals(mod_2)
```



```
##  
## Ljung-Box test  
##  
## data: Residuals from ARIMA(1,0,0)(1,1,0)[6]  
## Q* = 12.98, df = 8, p-value = 0.1125  
##  
## Model df: 2. Total lags used: 10
```

Perhatikan bahwa  $p\text{-value} = 0.1125 > \alpha = 0.05$  sehingga dapat disimpulkan bahwa data saling bebas. Hal ini juga diperkuat dari plot ACF yang tidak signifikan. Dapat dilihat juga bahwa distribusi dari residual hampir menyerupai distribusi normal dan plot residual terlihat memiliki rata-rata nol dan variansi yang konstan.

```
data_residuals <- residuals(mod_2)  
ks.test(residuals(mod_2), "pnorm", mean=mean(data_residuals), sd=sd(data_residuals))
```

```
##
## One-sample Kolmogorov-Smirnov test
##
## data: residuals(mod_2)
## D = 0.059726, p-value = 0.8358
## alternative hypothesis: two-sided
```

Uji Kolmogorov-Smirnov dengan hipotesis:

$H_0$ : data berdistribusi normal

$H_1$ : data tidak berdistribusi normal

Diperoleh  $p\text{-value} = 0.8358 > \alpha = 0.05$  maka  $H_0$  tidak ditolak dan dapat disimpulkan bahwa residual model berdistribusi normal.

```
ArchTest(data_residuals)
```

```
##
## ARCH LM-test; Null hypothesis: no ARCH effects
##
## data: data_residuals
## Chi-squared = 7.1079, df = 12, p-value = 0.8504
```

Karena  $p\text{-value} = 0.8504 > \alpha = 0.05$ , dapat disimpulkan bahwa data tidak perlu dimodelkan dengan model heteroskedastik. Hal ini didukung pula oleh variansi galat yang terlihat konstan pada plot galat.

## 5.1 Forecasting

Sebelum dilakukan forecasting, akan dilihat terlebih dahulu performa model untuk memodelkan data validation terlebih dahulu.

```
validation <- forecast(pm10_train,model=mod_2,h=length(pm10_validation))
actual <- as.vector(pm10_validation)
rmse_validation <- sqrt(mean((as.vector(validation$mean)-actual)^2))
rmse_validation

## [1] 10.90673
```

Dapat dilihat bahwa RMSE dari model  $\approx 10.907$  yang masih lebih kecil dari standar deviasi data. Dengan demikian, dapat disimpulkan bahwa model yang dipilih dapat digunakan untuk memprediksi data.

```
ape_validation <- abs((as.vector(validation$mean) -actual)/actual)*100
mape_validation <- mean(ape_validation)
mape_validation

## [1] 19.45461
```

Diperoleh juga MAPE sebesar  $\approx 19.455$

```
fc <- forecast(pm10,model=mod_2, h=24)
summary(fc)


##
## Forecast method: ARIMA(1,0,0)(1,1,0)[6]
##
```

```

## Model Information:
## Series: object
## ARIMA(1,0,0)(1,1,0)[6]
##
## Coefficients:
##          ar1          sar1
##      0.7803   -0.8099
## s.e.  0.0000    0.0000
##
## sigma^2 estimated as 61.03: log likelihood=-440.19
## AIC=882.38   AICc=882.41   BIC=885.21
##
## Error measures:
##              ME      RMSE      MAE      MPE      MAPE      MASE
ACF1
## Training set 0.5019865 7.565238 5.961525 -0.3123265 11.50245 0.8064 -0.1
741342
##
## Forecasts:
##      Point Forecast      Lo 80      Hi 80      Lo 95      Hi 95
## 133      56.38941 46.37811 66.40072 41.07844 71.70039
## 134      39.70816 27.00999 52.40634 20.28798 59.12834
## 135      48.43504 34.34991 62.52016 26.89369 69.97638
## 136      44.26175 29.39549 59.12802 21.52576 66.99774
## 137      55.76738 40.44505 71.08970 32.33390 79.20086
## 138      61.71389 46.12044 77.30733 37.86576 85.56201
## 139      61.07299 44.93353 77.21245 36.38982 85.75617
## 140      62.62455 46.16155 79.08756 37.44656 87.80254
## 141      69.43444 52.77754 86.09134 43.95991 94.90897
## 142      61.34541 44.57157 78.11926 35.69203 86.99879
## 143      59.03569 42.19105 75.88033 33.27403 84.79735
## 144      61.77427 44.88667 78.66187 35.94692 87.60162
## 145      57.42937 38.09756 76.76117 27.86392 86.99481
## 146      44.18210 23.50327 64.86093 12.55656 75.80764
## 147      52.51886 31.06134 73.97638 19.70241 85.33531
## 148      47.58104 25.66300 69.49909 14.06028 81.10180
## 149      56.44419 34.25047 78.63792 22.50181 90.38658
## 150      61.76857 39.40867 84.12847 27.57206 95.96509
## 151      60.41390 37.44018 83.38762 25.27863 95.54917
## 152      59.14418 35.80467 82.48368 23.44949 94.83887
## 153      66.23861 42.67920 89.79802 30.20760 102.26962
## 154      58.74424 35.05195 82.43653 22.51001 94.97848
## 155      58.55543 34.78261 82.32826 22.19804 94.91283
## 156      61.78294 37.96122 85.60465 25.35076 98.21511

plot(forecast(mod_2, h=24, level=c(80,95)), xaxt='n', ylab="Konsentrasi PM10
(μgr/m^3)", xlab="Bulan/Tahun", main="Forecast ARIMA(1,0,0)(1,1,0)[6] untuk
Konsentrasi PM10 di Kelapa Gading")
axis(1, at=seq(1, 140,10), labels=format(seq(as.Date("2010/1/1"), by = "yea
r", length.out = 14),format("%b %Y")), cex.axis=0.8, xpd=TRUE)

```




#### 4) Syntax pemodelan PM10 di stasiun DKI 3

##### Library yang digunakan

```
# Untuk membaca data dengan format csv
library(readr)
# Untuk membersihkan data
library(tidy)
# Untuk mengubah data menjadi Time Series,
# membuat plot ACF, plot PACF, Model ARIMA dan ADF Test
library(tseries)
# Untuk melihat signifikansi koefisien dari parameter
library(lmtest)
# Untuk memprediksi data dari model
library(forecast)
# Untuk melakukan uji heteroskedastik
library(FinTS)

# Memanggil Data
setwd("E:/Praktikum ADW")
library(readr)
data <- read_csv("ispu_stasiun.csv",
  col_types = cols(`bulan/tahun` = col_date(format = "%m/%Y"),
    `DKI 1` = col_number(), `DKI 2` = col_number(),
    `DKI 3` = col_number(), `DKI 4` = col_number()))
# Membuat grafik data
plot(data$`bulan/tahun`, data$`DKI 3`, type = 'l', main = 'Konsentrasi PM10
di Jagakarsa Tahun 2010-2021', xlab = "Tahun", ylab = "Konsentrasi PM10 (µg
r/m³)")
# Membuat garis rata-rata
abline(h=mean(data$`DKI 3`), lwd=2,
lty = 2, col = 'red')
```





```
summary(data$`DKI 3`)
```


```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    10.52  30.21   46.57   43.25  55.11   67.90
```

```
sd(data$`DKI 3`)
```

```
## [1] 15.24656
```


```
acf(data$`DKI 3`, lag = 48, main="Plot ACF Data")
```

### Plot ACF Data




Seperti data di daerah stasiun DKI lainnya, akan diasumsikan bahwa data memiliki pola musiman dengan  $s = 6$

```
# Membuat data menjadi time series
ts_data <- ts(data$`DKI 3`, frequency = 6)
#Plot per subseries
ggsubseriesplot(ts_data)
```



```
plot(decompose(ts_data))
```

### Decomposition of additive time series




Dari plot subseries dan dekomposisi terlihat bahwa memang terdapat pola musiman dari data tetapi tidak begitu nampak di plot ACF yang mungkin disebabkan oleh data yang belum stasioner.

Pada data terdapat 132 observasi yang berarti terdapat 11 tahun. Dengan demikian, jumlah observasi yang akan menjadi data train adalah sebanyak  $0.8 \times 11 \text{ tahun} \approx 9 \text{ tahun} = 114$  observasi dan sisa datanya akan menjadi data validation

```
# Membuat data train dan validation dan mengubahnya menjadi data time series
pm10 <- ts(data$`DKI 3`)
# data yang akan digunakan untuk membuat model
pm10_train <- ts(pm10[1:108])
# data yang akan digunakan untuk memvalidasi model
pm10_validation <- ts(pm10[108:132])
```

## 2. Identifikasi Model

```
# Membuat grafik data
plot(pm10_train, type = 'l', main = 'Konsentrasi PM10 Data Train', ylab =
"Konsentrasi PM10")
# Membuat garis rata-rata
abline(h=mean(pm10_train), lwd=2, lty = 2, col = 'red')
```




```
adf.test(pm10_train)
```

```
##
## Augmented Dickey-Fuller Test
##
## data: pm10_train
```

```
## Dickey-Fuller = -2.7355, Lag order = 4, p-value = 0.2716
## alternative hypothesis: stationary
```

Diperoleh nilai  $p\text{-value} = 0.1913 > \alpha = 0.05$  sehingga dapat disimpulkan bahwa data belum stasioner sehingga akan dilakukan diferensiasi

```
pm10_train_diff <- diff(pm10_train, lag = 6)
plot(pm10_train_diff, lwd = 2, main = 'Plot Data Diferensiasi Musiman', ylab =
"PM10 Train Diff")
abline(h = mean(pm10_train_diff), lwd = 2, lty = 2, col = 'red')
```




```
adf.test(pm10_train_diff)

## Warning in adf.test(pm10_train_diff): p-value smaller than printed p-value
##
## Augmented Dickey-Fuller Test
##
## data: pm10_train_diff
## Dickey-Fuller = -6.5861, Lag order = 4, p-value = 0.01
## alternative hypothesis: stationary
```

Diperoleh bahwa  $p\text{-value} < \alpha = 0.05$  maka dapat disimpulkan bahwa data telah stasioner dan dapat langsung ditentukan modelnya.


```
acf(pm10_train_diff, main = "Grafik ACF Data Diferensiasi Musiman", lag.max = 36)
```

**Grafik ACF Data Diferensiasi Musiman**



```
pacf(pm10_train_diff, main = "Grafik PACF Data Diferensiasi Musiman", lag.max = 49)
```

**Grafik PACF Data Diferensiasi Musiman**



Dari grafik-grafik tersebut dapat disimpulkan beberapa model yang akan dicoba, yaitu: 1.  $SARIMA(0,0,2) \times (1,1,1)_6$  2.  $SARIMA(1,0,0) \times (1,1,1)_6$  3.  $SARIMA(1,0,2) \times (1,1,1)_6$  4.  $SARIMA(0,0,2) \times (1,1,2)_6$  5.  $SARIMA(1,0,0) \times (1,1,2)_6$  6.  $SARIMA(1,0,2) \times (1,1,2)_6$  7.  $SARIMA(1,0,0) \times (0,1,1)_6$

### 3. PENAKSIRAN PARAMETER

```
mod_1 <- arima(pm10_train, order = c(0,0,2), seasonal = list(order = c(1,1,
1), period = 6),
               method = 'ML')
mod_1

##
## Call:
## arima(x = pm10_train, order = c(0, 0, 2), seasonal = list(order = c(1, 1
, 1),
##      period = 6), method = "ML")
##
## Coefficients:
##          ma1      ma2      sar1      sma1
##      0.6826  0.3052  0.1293  -0.6792
## s.e.  0.0969  0.1049  0.6059   0.5808
##
## sigma^2 estimated as 142: log likelihood = -399.1, aic = 808.2

mod_2 <- arima(pm10_train, order = c(1,0,0), seasonal = list(order = c(1,1,
1), period = 6),
               method = 'ML')
mod_2

##
## Call:
## arima(x = pm10_train, order = c(1, 0, 0), seasonal = list(order = c(1, 1
, 1),
##      period = 6), method = "ML")
##
## Coefficients:
##          ar1      sar1      sma1
##      0.7312  0.0760  -0.8076
## s.e.  0.0746  0.3487   0.3936
##
## sigma^2 estimated as 123: log likelihood = -393.23, aic = 794.46

mod_3 <- arima(pm10_train, order = c(1,0,2), seasonal = list(order = c(1,1,
1), period = 6),
               method = 'ML')
mod_3

##
## Call:
## arima(x = pm10_train, order = c(1, 0, 2), seasonal = list(order = c(1, 1
, 1),
##      period = 6), method = "ML")
##
## Coefficients:
##          ar1      ma1      ma2      sar1      sma1
##      0.8466 -0.1775 -0.0696 -0.0282 -0.7894
## s.e.  0.1230  0.1721  0.1573  0.2722  0.2893
##
## sigma^2 estimated as 121.6: log likelihood = -392.72, aic = 797.45
```

```

mod_4 <- arima(pm10_train, order = c(0,0,2), seasonal = list(order = c(1,1,
2), period = 6),
               method = 'ML')
mod_4

##
## Call:
## arima(x = pm10_train, order = c(0, 0, 2), seasonal = list(order = c(1, 1
, 2),
##      period = 6), method = "ML")
##
## Coefficients:
##          ma1      ma2      sar1      sma1      sma2
##      0.6436  0.2773 -0.9989  0.4708 -0.5113
## s.e.  0.0983  0.0856   0.0111  0.1251   0.1162
##
## sigma^2 estimated as 136.4: log likelihood = -398.32, aic = 808.63

mod_5 <- arima(pm10_train, order = c(1,0,0), seasonal = list(order = c(1,1,
2), period = 6),
               method = 'ML')

## Warning in arima(pm10_train, order = c(1, 0, 0), seasonal = list(order =
c(1, :
## possible convergence problem: optim gave code = 1

mod_5

##
## Call:
## arima(x = pm10_train, order = c(1, 0, 0), seasonal = list(order = c(1, 1
, 2),
##      period = 6), method = "ML")
##
## Coefficients:
##          ar1      sar1      sma1      sma2
##      0.7190 -0.9940  0.2877 -0.6669
## s.e.  0.0764   0.0341  0.1496   0.1370
##
## sigma^2 estimated as 120.7: log likelihood = -392.48, aic = 794.96

mod_6 <- arima(pm10_train, order = c(1,0,2), seasonal = list(order = c(1,1,
2), period = 6),
               method = 'ML')

## Warning in arima(pm10_train, order = c(1, 0, 2), seasonal = list(order =
c(1, :
## possible convergence problem: optim gave code = 1

mod_6

##
## Call:
## arima(x = pm10_train, order = c(1, 0, 2), seasonal = list(order = c(1, 1
, 2),
##      period = 6), method = "ML")

```

```
##
## Coefficients:
##          ar1          ma1          ma2          sar1          sma1          sma2
##          0.8801 -0.2479 -0.0899 -0.9972  0.1764 -0.7851
## s.e.  0.1130  0.1662  0.1558  0.0203  0.1846  0.1766
##
## sigma^2 estimated as 114.8: log likelihood = -391.5, aic = 797

mod_7 <- arima(pm10_train, order = c(1,0,0), seasonal = list(order = c(0,1,
1), period = 6),
               method = 'ML')
mod_7

##
## Call:
## arima(x = pm10_train, order = c(1, 0, 0), seasonal = list(order = c(0, 1
, 1),
##      period = 6), method = "ML")
##
## Coefficients:
##          ar1          sma1
##          0.7272 -0.7294
## s.e.  0.0736  0.1233
##
## sigma^2 estimated as 124.4: log likelihood = -393.26, aic = 792.51

mod_auto = auto.arima(pm10_train, max.p=4,max.q=4, max.P = 4, max.Q = 4,sea
sonal =TRUE, stationary = FALSE)
mod_auto

## Series: pm10_train
## ARIMA(1,1,1)
##
## Coefficients:
##          ar1          ma1
##          0.5339 -0.8537
## s.e.  0.1367  0.0845
##
## sigma^2 estimated as 110.6: log likelihood=-402.79
## AIC=811.59 AICc=811.82 BIC=819.6
```

Dapat dilihat bahwa model dengan AIC terkecil dimiliki oleh model  $SARIMA(1,0,0) \times (0,1,1)_6$  sehingga akan dipilih model tersebut untuk dianalisis lebih lanjut. Berikutnya, akan dilakukan uji signifikansi dari model.

#### 4. Signifikansi dari Koefisien Parameter dan Pembuatan Model

```
coeftest(mod_7)

##
## z test of coefficients:
##
##      Estimate Std. Error z value Pr(>|z|)
## ar1    0.727201   0.073618  9.8781 < 2.2e-16 ***
## sma1 -0.729376   0.123282 -5.9163 3.293e-09 ***
```



```
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Dapat dilihat bahwa semua parameter signifikan sehingga dapat disimpulkan bahwa model yang dipilih dapat digunakan untuk memodelkan data. Berikutnya, akan dilihat performa model.


```
accuracy(mod_7)
```

```
##              ME      RMSE      MAE      MPE      MAPE      MASE
ACF1
## Training set 0.418365 10.83773 8.096342 -7.058697 24.1523 0.9990044 -0.0
5699761
```

Dapat dilihat bahwa RMSE dari model sebesar 10.838 yang sangat kecil dibandingkan dengan standar deviasi data (= 15.247). Jadi, dapat disimpulkan bahwa model ini cocok digunakan untuk memodelkan data yang ada.

### 5. Uji Diagnostik

```
checkresiduals(mod_7)
```



```
##
##  Ljung-Box test
##
## data:  Residuals from ARIMA(1,0,0)(0,1,1)[6]
## Q* = 7.6364, df = 8, p-value = 0.4698
##
## Model df: 2.    Total lags used: 10
```

Perhatikan bahwa  $p\text{-value} = 0.4698 > \alpha = 0.05$  sehingga dapat disimpulkan bahwa data saling bebas. Hal ini juga diperkuat dari plot ACF yang tidak signifikan. Dapat dilihat juga bahwa distribusi dari residual hampir menyerupai distribusi normal dan plot residual terlihat memiliki rata-rata nol dan variansi yang konstan.

```
data_residuals <- residuals(mod_7)
ks.test(residuals(mod_7), "pnorm", mean=mean(data_residuals), sd=sd(data_residuals))

##
## One-sample Kolmogorov-Smirnov test
##
## data: residuals(mod_7)
## D = 0.058919, p-value = 0.8476
## alternative hypothesis: two-sided
```

Uji Kolmogorov-Smirnov dengan hipotesis:

$H_0$ : data berdistribusi normal

$H_1$ : data tidak berdistribusi normal

Diperoleh  $p\text{-value} = 0.8476 > \alpha = 0.05$  maka  $H_0$  tidak ditolak dan dapat disimpulkan bahwa residual model berdistribusi normal.

```
ArchTest(data_residuals)
```

```
##
## ARCH LM-test; Null hypothesis: no ARCH effects
##
## data: data_residuals
## Chi-squared = 9.377, df = 12, p-value = 0.6704
```

Karena  $p\text{-value} = 0.6704 > \alpha = 0.05$ , dapat disimpulkan bahwa data tidak perlu dimodelkan dengan model heteroskedastik. Hal ini didukung pula oleh variansi galat yang terlihat konstan pada plot galat.

## 5.1 Forecasting

Sebelum dilakukan forecasting, akan dilihat terlebih dahulu performa model untuk memodelkan data validation terlebih dahulu.

```
validation <- forecast(pm10_train, model=mod_7, h=length(pm10_validation))
actual <- as.vector(pm10_validation)
rmse_validation <- sqrt(mean((as.vector(validation$mean)-actual)^2))
rmse_validation

## [1] 7.055449
```

Dapat dilihat bahwa RMSE dari model  $\approx 7.0554$  yang lebih kecil dibandingkan dengan RMSE yang diperoleh sebelumnya. Dengan demikian, dapat disimpulkan bahwa model yang dipilih dapat digunakan untuk memprediksi data.

```
ape_validation <- abs((as.vector(validation$mean) - actual)/actual)*100
mape_validation <- mean(ape_validation)
mape_validation
```


```
## [1] 11.82231
```

Diperoleh juga MAPE sebesar  $\approx 11.822$

```
fc <- forecast(pm10,model=mod_7, h=24)
summary(fc)

##
## Forecast method: ARIMA(1,0,0)(0,1,1)[6]
##
## Model Information:
## Series: object
## ARIMA(1,0,0)(0,1,1)[6]
##
## Coefficients:
##          ar1          sma1
##      0.7272   -0.7294
## s.e.  0.0000   0.0000
##
## sigma^2 estimated as 124.4:  log likelihood=-475.17
## AIC=952.33   AICc=952.37   BIC=955.17
##
## Error measures:
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set 0.3605194 10.06241 7.393646 -5.88345 21.24156 0.9932244
##              ACF1
## Training set -0.04643071
##
## Forecasts:
##      Point Forecast      Lo 80      Hi 80      Lo 95      Hi 95
## 133      52.53454 38.24276 66.82632 30.67715 74.39193
## 134      52.44390 34.77276 70.11504 25.41823 79.46958
## 135      56.91170 37.69219 76.13120 27.51800 86.30540
## 136      53.01259 33.02270 73.00248 22.44069 83.58449
## 137      53.73659 33.35107 74.12211 22.55962 84.91356
## 138      50.69116 30.09949 71.28283 19.19892 82.18340
## 139      51.37477 29.93200 72.81754 18.58089 84.16865
## 140      51.60052 29.72105 73.47999 18.13876 85.06228
## 141      56.29839 34.19147 78.40530 22.48878 90.10800
## 142      52.56659 30.34034 74.79284 18.57447 86.55871
## 143      53.41226 31.12316 75.70136 19.32402 87.50050
## 144      50.45531 28.13304 72.77758 16.31634 84.59427
## 145      51.20326 28.38074 74.02578 16.29922 86.10729
## 146      51.47580 28.39311 74.55848 16.17388 86.77772
## 147      56.20769 32.98860 79.42677 20.69716 91.71821
## 148      52.50063 29.20974 75.79153 16.88028 88.12098
## 149      53.36430 30.03552 76.69307 17.68601 89.04258
## 150      50.42043 27.07164 73.76922 14.71154 86.12932
## 151      51.17789 27.38598 74.96981 14.79130 87.56449
## 152      51.45735 27.43440 75.48030 14.71742 88.19728
## 153      56.19427 32.05004 80.33850 19.26886 93.11969
## 154      52.49088 28.28276 76.69900 15.46776 89.51400
## 155      53.35720 29.11536 77.59904 16.28251 90.43189
## 156      50.41527 26.15562 74.67492 13.31334 87.51720
```

```
plot(forecast(mod_7, h=24, level=c(80,95)), xaxt='n', ylab="Konsentrasi PM10
( $\mu\text{gr}/\text{m}^3$ )", xlab="Bulan/Tahun", main="Forecast ARIMA(1,0,0)(0,1,1)[6] untuk
Konsentrasi PM10 di Jagakarsa", asp=0.6)
axis(1, at=seq(1, 140, 10), labels=format(seq(as.Date("2010/1/1"), by = "yea
r", length.out = 14), format("%b %Y")), cex.axis=0.8, xpd=TRUE)
```




5) *Syntax* pemodelan PM10 di stasiun DKI 4

### Library yang digunakan

```
# Untuk membaca data dengan format csv
library(readr)
# Untuk membersihkan data
library(tidy)
# Untuk mengubah data menjadi Time Series,
# membuat plot ACF, plot PACF, Model ARIMA dan ADF Test
library(tseries)
# Untuk melihat signifikansi koefisien dari parameter
library(lmtest)
# Untuk memprediksi data dari model
library(forecast)
# Untuk melakukan uji heteroskedastik
library(FinTS)

# Memanggil Data
setwd("E:/Praktikum ADW")
library(readr)
data <- read_csv("ispu_stasiun.csv",
  col_types = cols(`bulan/tahun` = col_date(format = "%m/%Y"),
    `DKI 1` = col_number(), `DKI 2` = col_number(),
    `DKI 3` = col_number(), `DKI 4` = col_number()))
# Membuat grafik data
plot(data$`bulan/tahun`, data$`DKI 4`, type = 'l', main = 'Konsentrasi PM10
di Lubang Buaya Tahun 2010-2021', xlab = "Tahun", ylab = "Konsentrasi PM10
( $\mu\text{gr}/\text{m}^3$ )")
# Membuat garis rata-rata
```

```
abline(h=mean(data$`DKI 4`),lwd=2,
lty = 2, col ='red')
```



```
summary(data$`DKI 4`)
```


```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##  31.81   54.83   61.93   63.36   71.09  111.43
```

```
sd(data$`DKI 4`)
```

```
## [1] 15.40222
```


```
acf(data$`DKI 4`, lag = 48, main="Plot ACF Data")
```

### Plot ACF Data




Pada grafik ACF dapat dilihat bahwa nilai ACF setiap lag kelipatan 6 lebih tinggi dari yang lain sehingga akan diasumsikan bahwa data memiliki pola musiman dengan  $s = 6$

```
# Membuat data menjadi time series
ts_data <- ts(data$`DKI 4`, frequency = 6)
#Plot per subseries
ggsubseriesplot(ts_data)
```



```
plot(decompose(ts_data))
```

## Decomposition of additive time series




Pada data terdapat 132 observasi yang berarti terdapat 11 tahun. Dengan demikian, jumlah observasi yang akan menjadi data train adalah sebanyak  $0.8 \times 11 \text{ tahun} \approx 9 \text{ tahun} = 108$  observasi dan sisa datanya akan menjadi data validation

```
# Membuat data train dan validation dan mengubahnya menjadi data time series
pm10 <- ts(data$`DKI 4`)
# data yang akan digunakan untuk membuat model
pm10_train <- ts(pm10[1:108])
# data yang akan digunakan untuk memvalidasi model
pm10_validation <- ts(pm10[108:132])
```

## 2. Identifikasi Model

```
# Membuat grafik data
plot(pm10_train, type = 'l', main = 'Konsentrasi PM10 Data Train', ylab =
"Konsentrasi PM10")
# Membuat garis rata-rata
abline(h=mean(pm10_train), lwd=2, lty = 2, col = 'red')
```

## Konsentrasi PM10 Data Train



```
adf.test(pm10_train)
```

```
## Warning in adf.test(pm10_train): p-value smaller than printed p-value
```

```
##
```

```
## Augmented Dickey-Fuller Test
```

```
##
```

```
## data: pm10_train
```

```
## Dickey-Fuller = -6.2525, Lag order = 4, p-value = 0.01
```

```
## alternative hypothesis: stationary
```

Diperoleh nilai  $p\text{-value} = 0.01 < \alpha = 0.05$  sehingga dapat disimpulkan bahwa data telah stasioner dalam rata-rata. sehingga akan dilakukan diferensiasi musiman


```
pm10_train_diff <- diff(pm10_train, lag = 6)
```

```
plot(pm10_train_diff, lwd = 2, main = 'Plot Data Diferensiasi Musiman', ylab =  
"PM10 Train Diff")
```

```
abline(h = mean(pm10_train_diff), lwd = 2, lty = 2, col = 'red')
```



### Plot Data Diferensiasi Musiman




```
adf.test(pm10_train_diff)

## Warning in adf.test(pm10_train_diff): p-value smaller than printed p-value
##
## Augmented Dickey-Fuller Test
##
## data: pm10_train_diff
## Dickey-Fuller = -9.8303, Lag order = 4, p-value = 0.01
## alternative hypothesis: stationary


acf(pm10_train_diff, main = "Grafik ACF Data Diferensiasi Musiman", lag.max = 36)
```

**Grafik ACF Data Diferensiasi Musiman**



```
pacf(pm10_train_diff, main = "Grafik PACF Data Diferensiasi Musiman", lag.m  
ax = 49)
```

**Grafik PACF Data Diferensiasi Musiman**



Dari grafik-grafik tersebut dapat disimpulkan beberapa model yang akan dicoba, yaitu: 1.  $SARIMA(0,0,2) \times (1,1,0)_6$  2.  $SARIMA(1,0,0) \times (1,1,0)_6$  3.  $SARIMA(1,0,1) \times (1,1,0)_6$  4.  $SARIMA(1,0,2) \times (1,1,0)_6$

### 3. PENAKSIRAN PARAMETER

```
mod_1 <- arima(pm10_train, order = c(0,0,2), seasonal = list(order = c(1,1,
0), period = 6),
               method = 'ML')
mod_1

##
## Call:
## arima(x = pm10_train, order = c(0, 0, 2), seasonal = list(order = c(1, 1
, 0),
##      period = 6), method = "ML")
##
## Coefficients:
##          ma1      ma2      sar1
##      0.5572  0.2836 -0.7970
## s.e.  0.1072  0.0927  0.0597
##
## sigma^2 estimated as 117.8: log likelihood = -391.18, aic = 790.36

mod_2 <- arima(pm10_train, order = c(1,0,0), seasonal = list(order = c(1,1,
0), period = 6),
               method = 'ML')
mod_2

##
## Call:
## arima(x = pm10_train, order = c(1, 0, 0), seasonal = list(order = c(1, 1
, 0),
##      period = 6), method = "ML")
##
## Coefficients:
##          ar1      sar1
##      0.6886 -0.7936
## s.e.  0.0774  0.0567
##
## sigma^2 estimated as 103.8: log likelihood = -384.73, aic = 775.46

mod_3 <- arima(pm10_train, order = c(1,0,1), seasonal = list(order = c(1,1,
0), period = 6),
               method = 'ML')
mod_3

##
## Call:
## arima(x = pm10_train, order = c(1, 0, 1), seasonal = list(order = c(1, 1
, 0),
##      period = 6), method = "ML")
##
## Coefficients:
##          ar1      ma1      sar1
##      0.8000 -0.2227 -0.8308
## s.e.  0.0837  0.1309  0.0558
##
## sigma^2 estimated as 100.5: log likelihood = -383.5, aic = 774.99
```

```

mod_4 <- arima(pm10_train, order = c(1,0,2), seasonal = list(order = c(1,1,
0), period = 6),
               method = 'ML')
mod_4

##
## Call:
## arima(x = pm10_train, order = c(1, 0, 2), seasonal = list(order = c(1, 1
, 0),
##      period = 6), method = "ML")
##
## Coefficients:
##          ar1          ma1          ma2          sar1
##      0.7675   -0.2982   0.2019   -0.8321
## s.e.  0.0898    0.1598   0.1667    0.0547
##
## sigma^2 estimated as 98.61:  log likelihood = -382.67,  aic = 775.34

mod_auto = auto.arima(pm10_train, max.p=4,max.q=4, max.P = 4, max.Q = 4,sea
sonal =TRUE, stationary = FALSE)
mod_auto

## Series: pm10_train
## ARIMA(0,1,0)
##
## sigma^2 estimated as 132.3:  log likelihood=-413.17
## AIC=828.34   AICc=828.38   BIC=831.02

```

Dapat dilihat bahwa model dengan AIC terkecil dimiliki oleh model  $SARIMA(1,0,1) \times (1,1,0)_6$  namun akan dipilih model  $SARIMA(1,0,0) \times (1,1,0)_6$  untuk dianalisis lebih lanjut karena memiliki nilai AIC yang tidak berbeda jauh tetapi memiliki parameter yang lebih sedikit. Berikutnya, akan dilakukan uji signifikansi dari model.

#### 4. Signifikansi dari Koefisien Parameter dan Pembuatan Model

```

coeftest(mod_2)

##
## z test of coefficients:
##
##      Estimate Std. Error  z value  Pr(>|z|)
## ar1    0.688591    0.077381   8.8987 < 2.2e-16 ***
## sar1  -0.793650    0.056734 -13.9891 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

Dapat dilihat bahwa semua parameter signifikan sehingga dapat disimpulkan bahwa model yang dipilih dapat digunakan untuk memodelkan data. Berikutnya, akan dilihat performa model.

```

accuracy(mod_2)

##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set 0.02701485 9.902168 7.840702 -1.742368 12.70888 0.8308288


```

```
## ACF1
## Training set -0.09641638
```

Dapat dilihat bahwa RMSE dari model sebesar 9.9022 yang sangat kecil dibandingkan dengan standar deviasi data (= 15.402). Jadi, dapat disimpulkan bahwa model ini cocok digunakan untuk memodelkan data yang ada.

## 5. Uji Diagnostik

```
checkresiduals(mod_2)
```



```
##
## Ljung-Box test
##
## data: Residuals from ARIMA(1,0,0)(1,1,0)[6]
## Q* = 10.514, df = 8, p-value = 0.2308
##
## Model df: 2. Total lags used: 10
```

Perhatikan bahwa  $p\text{-value} = 0.2308 > \alpha = 0.05$  sehingga dapat disimpulkan bahwa data saling bebas. Hal ini juga diperkuat dari plot ACF yang tidak signifikan. Dapat dilihat juga bahwa distribusi dari residual hampir menyerupai distribusi normal dan plot residual terlihat memiliki rata-rata nol dan variansi yang konstan.

```
data_residuals <- residuals(mod_2)
ks.test(residuals(mod_2), "pnorm", mean=mean(data_residuals), sd=sd(data_residuals))
```

```
##
## One-sample Kolmogorov-Smirnov test
##
```

```
## data: residuals(mod_2)
## D = 0.058803, p-value = 0.8493
## alternative hypothesis: two-sided
```

Uji Kolmogorov-Smirnov dengan hipotesis:

$H_0$ : data berdistribusi normal

$H_1$ : data tidak berdistribusi normal

Diperoleh  $p\text{-value} = 0.8493 > \alpha = 0.05$  maka  $H_0$  tidak ditolak dan dapat disimpulkan bahwa residual model berdistribusi normal.

```
ArchTest(data_residuals)
```

```
##
## ARCH LM-test; Null hypothesis: no ARCH effects
##
## data: data_residuals
## Chi-squared = 10.678, df = 12, p-value = 0.5567
```

Karena  $p\text{-value} = 0.5567 > \alpha = 0.05$ , dapat disimpulkan bahwa data tidak perlu dimodelkan dengan model heteroskedastik. Hal ini didukung pula oleh variansi galat yang terlihat konstan pada plot galat.

## 5.1 Forecasting

Sebelum dilakukan forecasting, akan dilihat terlebih dahulu performa model untuk memodelkan data validation terlebih dahulu.

```
validation <- forecast(pm10_train,model=mod_2,h=length(pm10_validation))
actual <- as.vector(pm10_validation)
rmse_validation <- sqrt(mean((as.vector(validation$mean)-actual)^2))
rmse_validation

## [1] 8.600851
```

Dapat dilihat bahwa RMSE dari model  $\approx 8.6008$  yang lebih kecil dibandingkan dengan RMSE yang diperoleh sebelumnya. Dengan demikian, dapat disimpulkan bahwa model yang dipilih dapat digunakan untuk memprediksi data.

```
ape_validation <- abs((as.vector(validation$mean) -actual)/actual)*100
mape_validation <- mean(ape_validation)
mape_validation

## [1] 12.91173
```

Diperoleh juga MAPE sebesar  $\approx 12.912$

```
fc <- forecast(pm10,model=mod_2, h=24)
summary(fc)

##
## Forecast method: ARIMA(1,0,0)(1,1,0)[6]
##
## Model Information:
## Series: object
## ARIMA(1,0,0)(1,1,0)[6]
```

```
##
## Coefficients:
##          ar1          sar1
##      0.6886   -0.7936
## s.e.  0.0000    0.0000
##
## sigma^2 estimated as 103.8:  log likelihood=-471.14
## AIC=944.27   AICc=944.31   BIC=947.11
##
## Error measures:
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set -0.1590777 9.693121 7.599728 -2.147416 12.76708 0.8436042
##              ACF1
## Training set -0.1081916
##
## Forecasts:
##      Point Forecast      Lo 80      Hi 80      Lo 95      Hi 95
## 133      53.47222 40.41419 66.53026 33.501686 73.44276
## 134      36.63251 20.77811 52.48691 12.385303 60.87972
## 135      47.44305 30.42255 64.46355 21.412446 73.47366
## 136      39.81651 22.27016 57.36286 12.981684 66.65134
## 137      49.51791 31.72766 67.30817 22.310068 76.72576
## 138      56.52531 38.62056 74.43005 29.142364 83.90825
## 139      56.34496 37.97978 74.71013 28.257847 84.43207
## 140      56.40971 37.83021 74.98922 27.994813 84.82462
## 141      64.47890 45.79862 83.15917 35.909884 93.04791
## 142      54.94791 36.22004 73.67577 26.306113 83.58970
## 143      54.71468 35.96429 73.46506 26.038438 83.39092
## 144      61.90939 43.14834 80.67045 33.216837 90.60195
## 145      54.04275 32.11294 75.97257 20.503992 87.58151
## 146      40.69821 17.41614 63.98027  5.091362 76.30505
## 147      50.94784 27.05133 74.84436 14.401277 87.49441
## 148      42.93161 18.74920 67.11401  5.947809 79.91540
## 149      50.58526 26.26847 74.90205 13.395945 87.77458
## 150      57.63287 33.25262 82.01311 20.346496 94.91923
## 151      55.86752 30.85190 80.88315 17.609426 94.12562
## 152      53.16601 27.85469 78.47733 14.455684 91.87634
## 153      61.68564 36.23531 87.13596 22.762719 100.60855
## 154      52.46757 26.95159 77.98354 13.444253 91.49088
## 155      53.86204 28.31500 79.40908 14.791210 92.93287
## 156      61.02657 35.46481 86.58832 21.933228 100.11990
```

```
plot(forecast(mod_2, h=24, level=c(80,95)), xaxt='n', ylab="Konsentrasi PM10
(µgr/m^3)", xlab="Bulan/Tahun", main="Forecast ARIMA(1,0,0)(1,1,0)[6] untuk
Konsentrasi PM10 di Lubang Buaya")
axis(1, at=seq(1, 140,10), labels=format(seq(as.Date("2010/1/1"), by = "yea
r", length.out = 14),format("%b %Y")), cex.axis=0.8, xpd=TRUE)
```

Forecast ARIMA(1,0,0)(1,1,0)[6] untuk Konsentrasi PM10 di Lubang Buaya

